


Rebellions Company Profile

| 리벨리온 회사 소개서

대한민국에서 시작된 기술, 리벨리온의 반란(rebellion)은 국경을 넘습니다.



리벨리온은 한국 최초의
딥테크 유니콘 스타트업으로,
AI 추론 시장에 특화된
NPU를 설계하는 팹리스 회사입니다.

사업 영역	AI반도체 설계
설립일	2020년 9월
전체 인원	320명
기업 가치	3.4조 원(2026년 7월 기준)

🏠 www.rebellions.ai

📍 경기도 성남시 분당구 정자일로156번길 6

Contents

01

Overview

회사 소개

회사 연혁
인재 구성
사업 영역
기술적 강점

02

Our Products

제품 소개

제품 라인업
전용 소프트웨어
▫ ATOM™-MAX
▫ REBEL100™

03

Partnerships

파트너사

주요 투자사
고객 및 협력사

회사 연혁

리벨리온은 압도적인 기술력을 기반으로 빠르게 성장하여, 국가대표 AI반도체 스타트업을 넘어 **세계로 도전**하고 있습니다.

2020 - 2023

- 2020. 9 리벨리온 설립
- 2020. 11 Seed 투자 유치(55억 원 규모)
- 2021. 7 Pre-A 투자 유치(145억 원 규모)
- 2021. 11 파이낸스향 AI반도체 아이온(ION™) 출시
- 2022. 7 시리즈A 투자 유치(920억 원 규모)
- 2023. 2 데이터센터향 AI반도체 아톰(ATOM™) 출시
- 2023. 5 국내 NPU 기업 최초 데이터센터 상용화

2024

- 2024. 1 시리즈B 투자 유치(1,650억 원 규모)
- 2024. 2 ISSCC 2024에서 아톰 성능 입증 논문 채택
- 2024. 7 아람코 Wa'ed Ventures 투자 유치(200억 원 규모)
- 2024. 9 아람코와 데이터센터 AI 혁신 위한 NPU 칩 공급 MOU 체결
- 2024. 10 Arm, 삼성전자와 차세대 AI 컴퓨팅 칩렛 기술 협력
- 2024. 11 대만 페가트론과 REBEL 기반 제품개발 위한 파트너십 체결
코리아 스타트업 어워즈 대상(중소벤처기업부 장관상)
차세대 AI반도체 리벨(REBEL) tape-out
- 2024. 12 SKT 자회사 '사피온코리아'와 합병 - 유니콘 등극
대한민국 ICT 대상(과학기술정보통신부 장관상)

2025

- 2025. 2 일본 법인 설립
- 2025. 3 SKT, 펙귄솔루션스와 AIDC 생태계 구축을 위한 MOU 체결
- 2025. 6 아톰맥스(ATOM™-Max) 출시
SKT AI 서비스에 리벨리온 NPU 적용 위한 테스트 착수
- 2025. 7 사우디아라비아 법인 설립


- 2025. 8 리벨100(REBEL100) 공개
- 2025. 9 시리즈C 투자 유치(3,500억 원 규모)
- 2025. 10 미국 법인 설립

2026

- 2026. 3 Pre-IPO 투자유치(6,400억원, 국민성장펀드 1호 직접투자)
- 2026. 4 Arm-SK텔레콤과 소버린 AI 및 통신사 겨냥 추론 인프라 협력
- 2026. 5 KB금융과 전략적 업무 제휴 협약 체결
- 2026. 6 AI 추론 최적화 기업 스퀴즈비츠 인수

인재 구성

리벨리온은 인재에 있어 타협하지 않습니다.
글로벌 경험을 지닌 **세계 최고 수준의 전문 인력**이 함께합니다.



Big-tech 경험을 갖춘 전문가



세계 유수 대학 출신의 인재



공동 창업자



		
박성현	오진욱	김효은
CEO, 대표이사 KAIST 전기 및 전자공학부 학사 MIT 전기공학 및 컴퓨터과학부 석사·박사 인텔, SpaceX, 모건스탠리	CTO, 최고기술책임자 서울대 전기컴퓨터공학부 학사 KAIST 전기 및 전자공학부 석사·박사 IBM, 현 KAIST 인공지능대학원 겸직교수	CPO, 최고제품책임자 KAIST 전기 및 전자공학부 학사·석사·박사 삼성전자, 루닛 CPO


주요 경영진

			
김홍석	신성규	정운석	Marshall Choy
CSA, 소프트웨어아키텍트총괄 서울대 전기전자공학부 학사 일리노이UIUC 컴퓨터과학 석·박사 메타·MS·삼성전자·구글코리아	CFO, 최고재무책임자 고려대 경영학과 학사 한국 공인회계사 삼일 PwC	CSO, 최고전략책임자 서울대 전기컴퓨터공학부 학사 하버드 통계학 석사, 응용물리학 박사 前 베인앤컴퍼니	CBO, 최고사업책임자 Sun Microsystems Oracle SambaNova Systems

사업 영역

리벨리온은 빠르게 성장하는 **AI 추론 시장**에 최적화된 **데이터센터용 반도체**를 개발합니다.

AI 추론 시장 성장성			
	필요 작업	최적 인프라	AI반도체 시장 규모 *출처: Bloomberg
AI 모델 개발단계 (Development)	AI 학습 (Training) 미리 확보한 데이터를 통해 LLM/Vision용 AI 모델 개발	 고성능 병렬 처리 장치 다양한 연산 지원, 범용성 높음 AI 학습에 적합	 203조 원 476조 원 2배 성장 2024 2030
AI 서비스 운영단계 (Deployment)	AI 추론 (Inference) 학습된 AI 모델을 서비스에 적용하여 결과를 실시간으로 생성하는 과정 (예: 챗봇 응답, 음성 명령 인식, 영상 내 객체 탐지 등)	 낮은 지연시간, 전력 소모 최소화 AI 추론과 같은 실시간 서비스에 최적	 56조 원 658조 원 12배 성장 2024 2030



리벨리온은 대규모 데이터센터, 클라우드업체(CSP), 보안성과 독립성이 중요한 **온프레미스 환경(On-premises)**을 위한 **에너지 효율적인 고성능 AI 반도체** 및 소프트웨어를 제공합니다.

기술적 강점

칩부터 소프트웨어, 인프라까지 - 리벨리온의 기술 경쟁력으로 AI 시대를 선도합니다.

에너지 효율성



AI 추론에 특화된 칩 설계로
GPU 대비 약 4.5배 우수한
전력 효율성

SW 개발



기존 GPU 사용자도
다양한 AI 모델을 쉽게 활용할 수 있도록
풀스택 소프트웨어 지원

확장성



카드부터 서버, 랙까지
다양한 구성으로 대규모 데이터센터도
효율적으로 운영 가능

기술 리더십



글로벌 기업과의 협업을 바탕으로
칩렛 기술, HBM 등
첨단 기술 리더십 확보

500건 이상의 기술 특허	글로벌 반도체 학회 채택 논문
▫ 리벨리온의 고유 기술로 전세계 500건 이상의 기술 특허 출원 및 등록 한국 미국 유럽 일본 중국 그외 합계 285 174 7 9 10 34 519 *2026년 3월 기준	Hot Chips 2022 ▫ LightTrader: World-first AI-enabled High-Frequency Trading Solution & 16TFLOPS/64 TOPS Deep Learning Inference Accelerators ISSCC 2024 ▫ ATOMUS: A 5nm 32TFLOPS / 128TOPS ML System-on-Chip for Latency Critical Applications · Demonstration Certificate of Recognition 수상 ICCAD 2025 ▫ CTDM: Resource-Efficient FPGA-Accelerated Simulation of Large-Scale NPU Designs ISSCC 2026 ▫ A Quad-Chiplet AI SoC with Full-Chip Scalable Mesh Over 16Gb/s UCle-Advanced Die-to-Die Interface for Large-Scale AI Inferencing


제품 라인업

다양한 규모의 AI 서비스를 위한 **하드웨어 솔루션 라인업**을 제공합니다.

리벨리온은 NPU 카드, 서버, 랙 단위까지 확장 가능한 제품 라인업을 제공합니다.

RSD(Rebellions Scalable Design) 아키텍처를 기반으로 규모가 커질수록 최적화된 성능과 효율을 자랑합니다.


카드 Card
칩을 탑재한 확장형 모듈로,
서버에 장착하여 AI 연산을 수행



4~16x Card

서버 Server


여러 개의 AI 가속 카드를 탑재해
대량의 AI 연산을 처리하는 장치



~14x Server

랙 Rack

여러 대의 서버를 하나로 연결해
대규모 AI 인프라를 구축하는 시스템



칩 Chip
AI 연산의 핵심 유닛으로,
NPU 성능을 결정하는 반도체 칩



전용 소프트웨어

GPU에서 쓰던 코드 그대로, 리벨리온의 풀스택 소프트웨어로 NPU에서도 손쉽게 개발이 가능합니다.

300개 이상의 AI 모델을 리벨리온 NPU에서 손쉽게 실행

OpenAI

gpt-oss



A.X LLM



Exaone



Solar



Llama



Mi:dm




QWEN-VL



SDXL-Turbo

업계 표준 AI 개발 프레임워크를 지원하여
기존 GPU 환경에서 사용하던 오픈소스 모델을 쉽게 적용 가능



ATOM™-MAX

대규모 AI 추론을 위한 고성능 AI 서버

대국민 AI 서비스를 구동하는 상용 NPU

SKT 에이닷 전화 통화요약, 반려동물 진단 보조 서비스 등
국내 첫 대규모 AI 서비스 상용화

광범위한 AI 모델 및 운영 환경 지원

수백 종의 AI 모델(Vision AI, LLM, 멀티모달 AI, Physical AI 등)과
핵심 AI 서비스 운영 도구(vLLM, Triton, K8s 등)를 지원

산업 현장 곳곳에 이미 적용된 NPU

건설, 보안, 통신, 의료, 공공 등 다양한 산업군의 AI 혁신 현장에 실제 도입되어 운영 중

국내 최초 양산 NPU

국내 최초 대량 양산을 실현하고, 고객사 AI 데이터센터에서의 검증과 상용화까지 완성



Rebel100™

국내 유일의 데이터센터향 고성능 서버 제품

AI 반도체 스타트업 최초, 페타플롭스급 연산 실현

아시아 스타트업 최고 수준 연산 성능. 고성능 GPU와 동등한 성능을
5세대 HBM(HBM3E)과 칩렛 기술로 실현

동일 성능, 3분의 1 비용

최신 GPU와 동등한 성능을 훨씬 낮은 비용과 전력으로 실현.
기존 공랭식 데이터센터에 바로 설치 가능해 별도 시설 투자 없이 즉시 운영 가능

서버 한대에서 국가 단위 인프라까지 확장

카드 한 장부터 서버, 데이터센터 전체 랙 규모까지 유연한 확장 지원.
소규모 도입부터 국가 AI 인프라 구축까지 단일 플랫폼으로 대응

AI 에이전트부터 초거대 AI 모델까지 구동

최근 주목받는 AI 에이전트, 초거대 언어모델, 추론 특화 모델까지
오픈소스 기반 소프트웨어로 기존 GPU 환경에서 손쉽게 전환 가능

* 페타플롭스(PetaFLOPS): 컴퓨터가 1초에 1,000조 번의 연산을 수행할 수 있는 능력의 단위



파트너사

주요 투자사	고객 및 협력사
기업가치 3.4조 누적투자금 1.3조 기업가치 3.4조 투자금 6,400억 한국산업은행 kt TEMASEK kakao DG Daiwa Ventures korelya aramco SK telecom SK hynix arm SAMSUNG Kindred Ventures TopTier 국민성장펀드 MIRAE ASSET 미래에셋증권 Seed/Pre-/시리즈A (~22.7) 시리즈 B (24.1) 사피온 코리아 합병 (24.12) 시리즈 C (25.9) 국민성장펀드 (26.3)	Design arm MARVELL SYNOPSYS ALPHAWAVE SEMI Production SAMSUNG SK hynix Amkor Technology PEGATRON Inventec Certification / Distribution SUPERMICR PENGUIN SOLUTIONS GIGABYTE DELL Hewlett Packard Enterprise Lenovo Software PyTorch Red Hat LLM THE LINUX FOUNDATION RAY Anyscale SqueezeBits lablup Partners SK telecom kt 과학기술정보통신부 산업통상부 SK telecom LG AI Research kt cloud NHN CLOUD NIA 한국지능정보사회진흥원 nipa 정보통신산업진흥원 LG전자 upstage aramco IBM Cloud KOMIPO 한국중부발전 ETRI 한국전자통신연구원 KONAN TECHNOLOGY Saltlux 데이터센터 · CSP 정부 · 공공 AI 모델 · 서비스

Thank you



ATOM™-Max Server

중소형 AI 모델/데이터 센터용 워크로드용

ATOM™-Max 서버는 고효율 전력 설계를 기반으로, 단일 서버만으로도 대규모 AI 추론을 안정적으로 수행합니다. Vision AI, LLM, 멀티모달 AI, Physical AI 등 수백 종의 AI 모델과 vLLM, Triton, Kubernetes 같은 핵심 AI 서비스 운영 도구를 지원합니다. GPU 친화적인 개발 환경을 제공해 손쉽게 활용할 수 있습니다.

Key Features



Performance at Any Scale

사용자 요청이 급증해도 성능 저하 없이 대규모 AI 서비스를 지원합니다. 단일 서버로도 수천 개 토큰과 프레임을 실시간 처리합니다.



Sustainable AI Infrastructure

고효율 전력 설계로 AI 인프라의 총소유비용(TCO)을 절감하며, 지속가능한 AI 비즈니스 환경을 구축할 수 있습니다.



Variety of Models Applications

LLM, Vision AI, 멀티모달 AI, Physical AI 등 수백 종의 AI 모델을 즉시 활용해 맞춤형 AI 서비스를 구현할 수 있습니다.



Develop As You Always Have

익숙한 개발 환경과 워크플로우(Pytorch, TensorFlow 등)를 그대로 활용할 수 있어 튜토리얼을 통해 쉽게 개발을 이어갈 수 있습니다.



Full-Stack Software Support

vLLM, Triton Inference Server, K8s 등 오픈소스 생태계와 호환되며, 효율적인 서빙, 유연한 자원 운영 및 모니터링을 위한 다양한 AI 서비스 운영 도구로 end-to-end 서비스 구축이 가능합니다.



Spec

NPU	ATOM™-Max NPU Card *8
NPU Memory	512GB GDDR6, 8TB/s
Performance	1,024 TFLOPS (FP16) 4,096 TOPS (INT8)
Form Factor	4U
CPU	5th Gen. AMD EPYC Processor *2
Memory	1.5TB
Storage	1.92TB SSD * 2
Network	10G 2Port * 1
Max Power Consumption	Typical 3.4kW (Max ~4.3kW)
Compatible Software	- OS: Ubuntu, RHEL, AlmaLinux, RockyLinux - Frameworks & Tools: Hugging Face, PyTorch, TensorFlow, Triton - Inference Serving: vLLM, Triton Inference Server, TorchServe, Ray Serve - Orchestration: Docker, OpenStack, Kubernetes

RBLN SDK

GPU의 익숙한 사용성을 제공하면서도, 차세대 AI 워크로드를 위해 설계된 Full-Stack Inference Platform을 제공합니다. PyTorch 개발부터 LLM 서빙과 배포까지, 모든 단계가 엔터프라이즈 환경에 맞춰 설계되었습니다.

Driver SDK

NPU 구동을 위한
기본 시스템 SW 및 도구 모음

- Firmware
- Kernel Driver
- User Mode Driver
- System Management Tool

NPU SDK


모델 및 서비스 개발을 위한 SW 도구 모음

- Compiler, Runtime, Profiler
- Hugging Face 지원
- 주요 추론 서버 지원
(vLLM, TorchServe, Triton Inference Server 등)

Model Zoo

리벨리온 NPU에서 곧바로 쓸 수 있는
300+ PyTorch와 TensorFlow 모델 제공

- Natural Language Processing
- Generative AI
- Speech Processing
- Computer Vision
- Physical AI



ATOM™-Max Server

sLM, Vision AI 등의 소규모 워크로드용

ATOM™-Max 서버는 고효율 전력 설계를 기반으로, 단일 서버만으로도 Enterprise용 AI 추론을 안정적으로 수행합니다. Vision AI, LLM, 멀티모달 AI, Physical AI 등 수백 종의 AI 모델과 vLLM, Triton, Kubernetes 같은 핵심 AI 서비스 운영 도구를 지원합니다. GPU 친화적인 개발 환경을 제공해 손쉽게 활용할 수 있습니다.

Key Features



Performance at Any Scale

사용자 요청이 급증해도 성능 저하 없이 대규모 AI 서비스를 지원합니다. 단일 서버로도 수천 개 토큰과 프레임을 실시간 처리합니다.



Sustainable AI Infrastructure

고효율 전력 설계로 AI 인프라의 총소유비용(TCO)을 절감하며, 지속가능한 AI 비즈니스 환경을 구축할 수 있습니다.



Variety of Models Applications

LLM, Vision AI, 멀티모달 AI, Physical AI 등 수백 종의 AI 모델을 즉시 활용해 맞춤형 AI 서비스를 구현할 수 있습니다.



Develop As You Always Have

익숙한 개발 환경과 워크플로우(Pytorch, TensorFlow 등)를 그대로 활용할 수 있어 튜토리얼을 통해 쉽게 개발을 이어갈 수 있습니다.



Full-Stack Software Support

vLLM, Triton Inference Server, K8s 등 오픈소스 생태계와 호환되며, 효율적인 서빙, 유연한 자원 운영 및 모니터링을 위한 다양한 AI 서비스 운영 도구로 end-to-end 서비스 구축이 가능합니다.

Spec

NPU	ATOM™-Max NPU Card *4
NPU Memory	256GB GDDR6, 4TB/s
Performance	512 TFLOPS (FP16) 2,048 TOPS (INT8)
Form Factor	2U
CPU	5th Gen. AMD EPYC Processor *1
Memory	768GB
Storage	1.92TB SSD * 2
Network	10G 2Port * 1
Max Power Consumption	2.6 kW
Compatible Software	- OS: Ubuntu, RHEL, AlmaLinux, RockyLinux - Frameworks & Tools: Hugging Face, PyTorch, TensorFlow, Triton - Inference Serving: vLLM, Triton Inference Server, TorchServe, Ray Serve - Orchestration: Docker, OpenStack, Kubernetes

RBLN SDK

GPU의 익숙한 사용성을 제공하면서도, 차세대 AI 워크로드를 위해 설계된 Full-Stack Inference Platform을 제공합니다. PyTorch 개발부터 LLM 서빙과 배포까지, 모든 단계가 엔터프라이즈 환경에 맞춰 설계되었습니다.

Driver SDK

NPU 구동을 위한
기본 시스템 SW 및 도구 모음

- Firmware
- Kernel Driver
- User Mode Driver
- System Management Tool

NPU SDK

모델 및 서비스 개발을 위한 SW 도구 모음

- Compiler, Runtime, Profiler
- Hugging Face 지원
- 주요 추론 서버 지원
(vLLM, TorchServe, Triton Inference Server 등)


Model Zoo

리벨리온 NPU에서 곧바로 쓸 수 있는
300+ PyTorch와 TensorFlow 모델 제공

- Natural Language Processing
- Generative AI
- Speech Processing
- Computer Vision
- Physical AI

Rebel100™


에너지 부담 없는
페타스케일 MoE 가속.



- 고효율·저전력으로 프론티어 LLM을 서빙하도록 설계
- 통합 혼합정밀 코어, 지능형 DMA 스케줄링, UCle 인터커넥트 기반
- 랙 스케일 성능. 모듈형 확장성. 즉시 배포 가능

Rebel100은 세계 최초의 **UCle-Advanced** 기반 AI 가속기 카드로, 초대규모 환경에서 효율적이고 확장 가능한 추론을 위해 설계되었습니다. 4개의 동일한 연산 칩릿을 고대역폭 UCle-Advanced 링크로 단일 SoC처럼 결합한 모듈형 아키텍처로 구현되었습니다. 이를 통해 단일 노드부터 멀티 랙 클러스터까지 매끄럽게 확장이 가능합니다.

가속기 카드 사양

Architecture		Host Connection
4-homogeneous-chiplet SoC based on UCle-Advanced		2x PCIe Gen5 x16
Compute (Dense)		Power Consumption
1,024 TFLOPS (FP16) 2,048 TFLOPS (FP8)		Up to 600W
External Memory		Software
HBM3E 144GB 4.8TB/s		Native-support of PyTorch 2.x, vLLM and Triton
Chiplet (UCle-A) Interconnection		 vLLM  PyTorch 2.x  Triton
16Gbps 1TB/s per channel		

SoC 아키텍처 핵심 기술



Unified Compute Engine: One Core for All Precisions

피연산자(operand) 단위 유연성을 갖춘 혼합정밀 코어가 FP8과 FP16을 단일 파이프라인에서 지원합니다. 명령어 전환을 제거해 연산 밀도를 ATOM™ 대비 2.8배 향상시킵니다.



Responsive DMA Scheduling: Memory Access Without Waiting

사전 컴파일된 DMA 엔진이 KV 캐시 접근을 명령어 수준 대역폭·QoS 제어와 함께 조율합니다. 그 결과 코어당 대역폭이 3.3배 향상되어 32K 토큰 디코딩도 매끄럽게 처리합니다.



Modular UCle Interconnect: Multiple Dies as One

4개의 칩렛이 채널당 1TB/s의 UCle-Advanced 링크로 하나의 시스템으로 통합됩니다. 동일한 인터커넥트가 외부로 확장되어 랙 스케일 분산 아키텍처까지 지원합니다.



Holistic Synchronization: Perfect Orchestration for Peta-Scale Workloads


하드웨어 가속 싱크 패브릭이 칩렛 전반의 실행을 동기화합니다. 희소형(sparse) 모델과 MoE 모델까지 포함해 미세 병렬 처리를 지원하고 전문가 라우팅 과정의 병목을 제거합니다.

Rebel100 vs. H200

(Llama 3.3 - 70B)

처리량
(TPS)

~x1.6



효율
(TPS/Watt)

~x3.2



전력 소모
(Watt)

~x0.5



벤치마크 조건: Llama 3.3 70B (TP2, FP8), 입력/출력 길이 2048/2048 기준 성능 측정.

Rebel100은 실리콘부터 시스템 규모까지 AI 인프라의 경제성을 새롭게 정의합니다.

Rebel100은 내부 평가에서 대규모 LLM 구동 시 NVIDIA H200급 GPU 대비 더 높은 처리량을 입증했습니다. 이는 컴퓨트와 메모리 병목을 동시에 해소하는 단일 모듈형 시스템 구조 덕분입니다. 현재는 I/O 다이를 포함한 차세대 REBEL 칩렛을 개발 중이며, 조 단위 파라미터 모델과 멀티 노드 엑사스케일 배포까지 확장할 수 있도록 설계되고 있습니다.