엠큐닉 AI 활용 현황과 K-NPU 전환·병행 도입 검토

AI-ITS 혁신을 위한 K-NPU 전환지원 밋업

2026. 10. 22



MQNIC

AI 플랫폼 기업, 엠큐닉



AI Platform Service
엔터프라이즈 LLM·지식기반 에이전트 플랫폼

생성형 AI
LLM·RAG·AI Agent

VLM 플랫폼
멀티모달 영상 분석·시맨틱 검색

온톨로지
지식 그래프

AIOps
자율 운영·품질 개선



AX · DX Service
이기종 시스템 통합·안정적 운영

대용량 데이터 통합·플랫폼
데이터 플랫폼 설계·구축·운영

분산 시스템 통합 운영
인프라·데이터·서비스 연계 관제



AX 전략 컨설팅
AI 도입 진단부터 운영까지

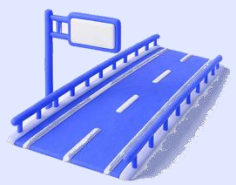
AI 도입 진단
파이프라인 설계·구축·운영 방향

AX 로드맵·이행계획
민간·공공·지자체 AI 전환 전략

MQNIC

ITS·AI 주요 사업 및 서비스

고속도로 교통 통합 플랫폼



CCTV·VMS·VSL 실시간 수집·처리

VLM 기반 지능형 도시 관제



영상 이벤트 탐지·시맨틱 검색

AI 교차로 신호 최적화



멀티에이전트 강화학습 신호·Offset 최적화

통신 데이터 기반 교통 분석



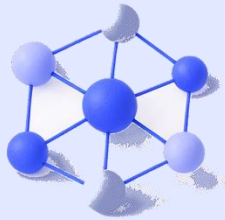
측위 기반 교통량 전수화·분석

자율주행 모빌리티센터 운영



자율차·EdgeRSU 관제, Lv.4/4+ 실증

온톨로지 AI 플랫폼



지식 그래프 기반 에이전트 자동화

해외 ITS: 카자흐스탄·우즈베키스탄, 방글라데시, 인도네시아, 콜롬비아

MQNIC

GPU 기반 AI 서비스와 활용 모델

02 생성형 AI (LLM·RAG)

LLM, 임베딩·리랭커, 문서 OCR·레이아웃

추론 + 파인튜닝

03 교통 예측·신호 최적화

시계열 예측, ML, 멀티에이전트 강화학습

학습 (배치)



04 온톨로지 / AIOps

LLM 기반 추론·근거 생성

추론

01 VLM 영상 관제·검색

VLM, 멀티모달 임베딩, Open-vocab 탐지, 리랭커

상시 추론

GPU 부하의 중심 → **VLM·LLM 상시 추론**

MQNIC

GPU 활용 및 운영 현황

01 R&D

- VLM·LLM 도메인 적응
- 모델 비교·평가

학습 / 평가

03 현장 납품

- 현장별 GPU 서버
- 독립 설치·유지보수

온프레미스



02 서비스 추론

- 다채널 영상 VLM 추론
- 임베딩·하이브리드 검색

24시간 상시

운영 특성 **공공 폐쇄망 · 온프레미스 · 현장 분산 배포 · 상시 추론**

MQNIC

K-NPU 검토 필요성



추론 TCO·전력 부담

현장 확산 시 장비비·전력 선형 증가



공공 정책·발주 환경

국산 AI 반도체 활용 확대 대응



공급 리스크 분산

단일 GPU 벤더 의존 완화



데이터 주권·폐쇄망

국산 HW·SW 기반 보안 요구 대응

검토 경과

완료

AWS Inferentia
/Trainium 테스트

진행 중

국산 NPU
물리 테스트 환경

오늘

K-NPU 기업·
지원기관 협력 모색

주요 고려사항과 적용 검토 분야

주요 고려사항

1	모델 지원 범위	LLM·VLM·멀티모달 구조
2	성능 대비 TCO	처리량·지연 대비 장비·전력
3	SW 스택 호환성	서빙·컨테이너 운영
4	정확도 유지	양자화·컴파일 후 성능
5	운영·공급 안정성	폐쇄망 배포, 장기 지원

병행 도입 구조 (안)



GPU

학습·연구
신규 모델 검증

→

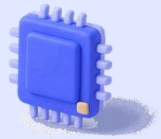
1순위 K-NPU

LLM·RAG
임베딩 추론



2순위 K-NPU

VLM
영상 관제 추론



3순위 K-NPU

엣지
1차 필터링



전환·병행 시 예상되는 애로사항

기술적 애로

최신 VLM 지원 시차
비전 인코더+LLM, 동적 해상도·다중 프레임



정적 shape·컴파일 제약
가변 입력, 모델 교체 시 재컴파일



양자화 후 정확도 검증
도메인 데이터로 재검증



커스텀 연산 이식
Open-vocab 탐지, 리랭킹, 전·후처리



운영적 애로

벤더별 코드베이스 분산
컴파일러·서빙·산출물 상이



폐쇄망 현장 배포
오프라인 설치, SDK 버전별 재컴파일



운영 체계 연동
컨테이너·모니터링 통합



도입 판단 근거 부족
ITS 워크로드 실측 비교 자료 부재



필요 지원

- 최적화
- SW 호환성
- 개발 환경

문의 및 요청 사항



K-NPU 기업에

01 VLM 지원 로드맵

멀티모달 모델 지원 일정 공유

02 표준 인터페이스

torch.compile·vLLM, 최신 모델 조기 지원

03 ITS 레퍼런스 벤치마크

다채널 영상 추론 등 대표 워크로드

04 폐쇄망·버전 호환

오프라인 패키지, SDK 간 산출물 호환



지원기관·정책에

01 K-NPU 테스트베드

장비 대여 + ITS 실데이터 실증환경

02 포팅 인건비 지원

모델 최적화 바우처 등

03 병행 실증 트랙

공공 ITS 사업 내 GPU–NPU 병행

04 검증 체계

NPU 기반 AI 서비스 성능·신뢰성

향후 K-NPU 도입 및 활용 계획 (안)

단기 ~ 2026 하반기

- 국산 NPU 테스트 환경 구축
- LLM·임베딩 포팅·벤치마크



중기 2027 상반기

- VLM 영상 추론 NPU 이식
- 현장 GPU–NPU 병행 운영



확산 2027 하반기 ~

- 공공 납품 K-NPU 옵션
- 엣지–서버 NPU 확대



학습은 GPU, 추론은 K-NPU

공공 ITS 현장에서 검증 가능한 병행 모델, NPU 기업·지원기관과 함께

감사합니다

MANIC