FURIOSA

ITS 기업을 위한 NPU 도입 가이드
ITS 세계총회 2026 · 강릉



우리의 미션은
AI 컴퓨팅을 지속 가능하게 만들어,
지구상의 모든 사람이
강력한 AI를 활용할 수 있게 하는 것



2017년 AMD, Qualcomm, Samsung 출신 엔지니어들이 설립,
한국과 실리콘밸리를 거점으로 글로벌 운영 중
(임직원 약 250명).

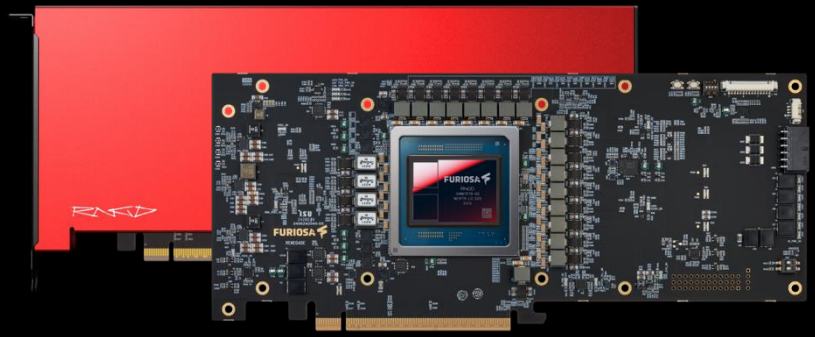
2021년 컴퓨터 비전 NPU 출시, 2024년 플래그십 데이터센터 칩
RNGD 공개 등 두 세대의 AI 칩 개발.

시리즈 C 브리지까지 총 $250M 투자 유치, TSMC, GUC,
SK Hynix, ASUS, Supermicro 등 글로벌 선도 파트너와 협력.

© 2026 FuriosaAI, Inc. · Confidential

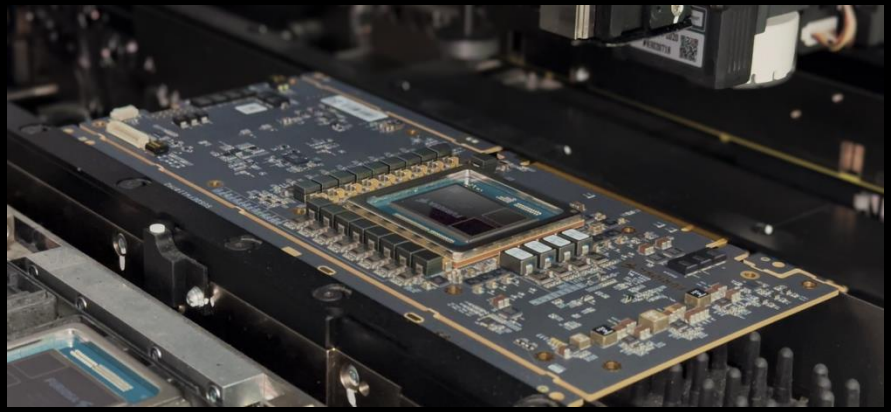
Furiosa RNGD (레니게이드), 고성능 AI 추론 칩

512 TFLOPS	48 GB	256 MB SRAM	1.5 TB/s	180 W TDP	2 × HBM3
64 TFLOPS (FP8) ×8 processing elements	메모리 용량	384 TB/s On-chip 대역폭	메모리 대역폭	공랭식	CoWoS-S



tsmc SK hynix GUC ASUS

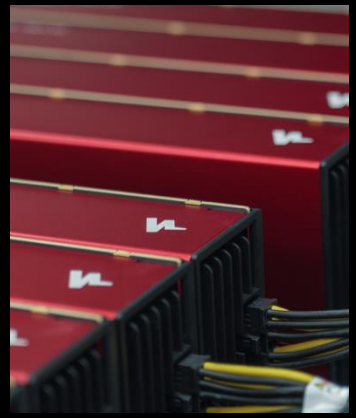
© 2026 FuriosaAI, Inc. · Confidential





Furiosa RNGD 2026년 1월 양산 개시
(연 2만장 규모), 국내외 도입·확산







Partners

© 2026 FuriosaAI, Inc. · Confidential

Furiosa NXT RNGD Server (넥스트 레니게이드 서버)

Agentic System을 위한 엔터프라이즈용 추론 어플라이언스 (3kW)

8× RNGD	4 petaFLOPS	384 GB	12 TB/s	3 kW
Cards	512 TFLOPS × 8 cards	HBM3 용량	메모리 대역폭	소비 전력



SUPERMICRO HPE arm cisco DELL GIGABYTE Lenovo

© 2026 FuriosaAI, Inc. · Confidential

ITS AI의 NPU 전환, 모험이 아니라 검증된 단계로.

모델과 SLO를 정의하고, 무상 리모트 Evaluation으로 적합성을 검증한 뒤, 하드웨어+솔루션 결합 협력으로 확장합니다.

ITS 기업이 지금 NPU를 검토하는 이유

01

엣지 현장의 제약

게이트, 노변 함체, 관제실은 전력·냉각·공간 여유가 크지 않습니다.

02

규모가 곧 비용

차로·교차로·카메라 그룹마다 같은 연산이 수백 번 반복됩니다.

03

멀티 모델 파이프라인

검출, OCR, 분류, 트랜스포머 모델이 하나의 실시간 흐름으로 동작합니다.

04

24시간 상시 운영

이벤트별 지연 목표가 있는 24/7 운영에서는 성능 편차가 허용되지 않습니다.

이제 질문은 “NPU에서 우리 모델이 돌아가는가?”가 아니라
“적합성을 얼마나 빠르게, 초기 부담 없이 검증할 수 있는가?”입니다.

© 2026 FuriosaAI Inc.

NPU 도입 로드맵: 사전 검토부터 사업 협력까지 4단계

	PHASE 0 사전 검토	PHASE 1 리모트 Evaluation	PHASE 2 PoC / 파일럿	PHASE 3 사업 협력
목표	대상 모델과 SLO 정의	RNGD에서 SLO 대비 모델 적합성 검증	전용 환경에서 규모 검증	하드웨어+솔루션 결합 으로 사업화
고객 준비 사항	모델 목록, SLO 목표, 배포 제약 조건	모델 파일, 샘플 데이터, 정확도 기준	현장 데이터, 연동 작업, 테스트 계획	ITS 솔루션, 영업 채널, 최종 고객
FuriosaAI 지원	모델 사전 검토, 포팅 리스크 파악	리모트 RNGD 평가 서버 + 적합성 검토 엔지니어링	전용 인프라, 서버·카드 임차, 현장 지원	RNGD 하드웨어, SDK, 공동 엔지니어링·GTM
산출물	Evaluation 계획 및 성공 기준	적합성 리포트: 정확도, 지연, 처리량, 사이징	PoC 리포트 및 배포 설계	사업 계약 및 공동 오퍼링
예상 기간*	1–2주	2–6주	1–3개월	협의
비용	무상	무상	유상: 인프라 / 서버 / 카드 임차	상용 계약 조건
	초기 모델 정합성 Evaluation		사업 단계	

* 참고용 기간이며, 모델 수와 복잡도, SLO 범위에 따라 달라집니다.

© 2026 FuriosaAI Inc.

Phase 0 — 사전 검토: 대상 모델과 SLO 정의

검토 항목	요청 자료	필요한 이유
모델 목록	모델 정보, 프레임워크(PyTorch), 가중치, 정밀도 등	컴파일 경로와 포팅 공수 결정
입출력 사양	입력 형태(정적/동적), 배치 크기, 전·후처리	정적 형태가 유리하며, 동적 입력은 패딩 방안 필요
파이프라인 구성	상시 구동 / 이벤트 구동 모델 구분, 모델 간 연결	PE 분할과 스케줄링 설계의 기준
정확도 기준	현재 GPU 기준 지표와 허용 오차	BF16 / FP8 정합성 판단 기준
샘플 데이터	모델별 대표 이미지 또는 영상	정확도 및 End-to-End 검증에 사용

산출물: 모델 컴파일 전에 합격/불합격 기준이 담긴 Evaluation 계획을 합의합니다.

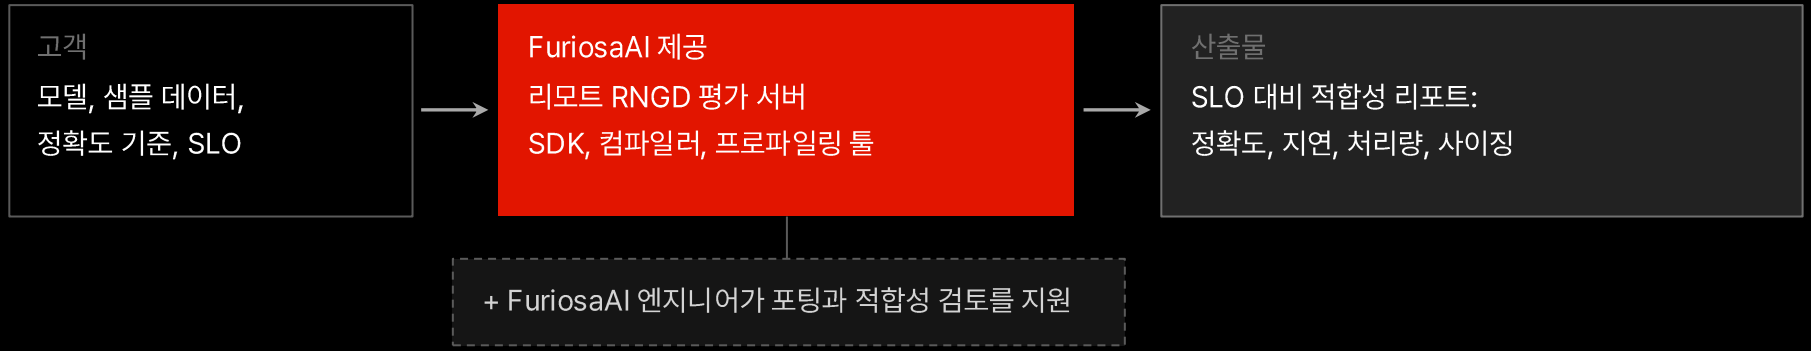
SLO 정의

지연 시간	모델별 / End-to-End p95·p99
처리량	카드·서버당 스트림 수 × FPS
정확도	GPU 기준 대비 최대 허용 편차
집적도·전력	카드당 스트림 수, 스트림당 전력
가용성	24/7 운영, 이중화 요건

예시(항만 게이트): 차로당 카메라 5대 × 30 FPS, 모델 13종, 24/7

© 2026 FuriosaAI Inc.

Phase 1 — 리모트 Evaluation: FuriosaAI 제공 RNGD 서버에서 적합성 검증



1

온보딩

리모트 서버 계정 발급, 모델·데이터 보안 업로드

2

컴파일·포팅

FP16 → BF16 변환, 정적 형태 처리, 연산자 지원 확인

3

정확도 정합성

GPU 기준 결과와 출력 비교

4

성능 측정

모델별 지연, 처리량, 배치, PE 할당

5

적합성 검토·사이징

SLO 대비 결과, 현장별 카드·서버 수

초기 모델 정합성 Evaluation은 리모트 서버 사용과 엔지니어링 지원을 포함합니다.

© 2026 FuriosaAI Inc.

Phase 2–3 — Evaluation 이후: PoC 옵션과 사업 협력 모델

Phase 2 · PoC / 파일럿

(필요 시) 일부 유상 — 구성과 기간에 따라 별도 견적

별도 인프라 환경

고객 데이터와 파이프라인, 장기 테스트를 위한 전용 환경

물리 서버 임차

연동·현장 테스트를 위해 RNGD 서버를 고객 랩 또는 현장에 제공

RNGD 카드 임차

고객 기존 서버에 장착해 자체 환경에서 검증

Phase 3 · 사업 협력

하드웨어 + 솔루션 결합

통합 어플라이언스

고객 ITS 애플리케이션을 RNGD 서버에 사전 탑재해 단일 제품으로 공급

공동 솔루션

파이프라인 공동 최적화, 레퍼런스 사이트 및 GTM 공동 추진

프로젝트 단위 공급

특정 현장·입찰에 FuriosaAI 하드웨어와 고객 솔루션을 함께 공급

Evaluation 결과는 그대로 이어집니다. Phase 1 적합성 리포트가 PoC 테스트 계획이 되고, 이후 공동 오퍼링의 레퍼런스 설계가 됩니다.

© 2026 FuriosaAI Inc.

지원 범위: 단계별 역할 분담

단계	업무	FuriosaAI	고객
0	모델·SLO 사전 검토	모델 목록 검토, 포팅 리스크 식별, 계획 제안	모델, SLO 목표, 제약 조건 공유
1	Evaluation 환경	리모트 RNGD 서버, SDK, 툴 제공(무상)	모델과 샘플 데이터 업로드
1	포팅·컴파일	컴파일, BF16 변환, 입력 형태 처리 주도	모델 관련 질의 대응, 변경 사항 승인
1	정확도·성능 검증	벤치마크 수행, SLO 대비 결과 리포트	기준 대비 정확도 확인
1	사이징·아키텍처	PE / 카드 / 서버 사이징 제안	현장 및 배포 제약 조건 공유
2	PoC 인프라	별도 환경, 서버·카드 임차 제공(유상)	현장, 네트워크, 연동, 테스트 계획
3	상용 배포	하드웨어, SDK 업데이트, 기술 지원	솔루션 통합, 최종 고객 납품

© 2026 FuriosaAI Inc.

예상 기간과 비용: 검증은 무상, 비용은 확장 단계부터



도입 결정까지 약 3–5개월(참고용). 단계는 일부 병행할 수 있으며, 기간은 모델 수와 SLO 범위에 따라 달라집니다.

무상

Phase 0–1

사전 검토, 리모트 평가 서버 사용, 초기 모델 정합성 확인을 위한 적합성 검토 지원

일부 유상

Phase 2

별도 인프라 환경, 물리 서버 임차, RNGD 카드 임차 — 구성과 기간에 따라 견적

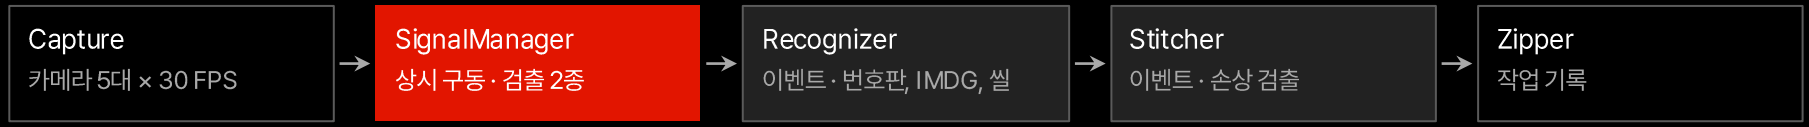
사업 협력

Phase 3

합의된 상용 조건에 따른 하드웨어 + 솔루션 결합 사업 협력

© 2026 FuriosaAI Inc.

적용 사례: 항만 AI 게이트 — 13개 모델의 Evaluation 진행



Phase 0 · 정의

트럭 게이트 자동화를 추진하는 글로벌 항만 운영사

5개 계열 13개 모델: YOLOv8 ×4, D-FINE-M, PP-OCRv6 ×3, ResNet / MobileNet ×4, ViT Depth

SLO: 차로당 카메라 5대 × 30 FPS, 24/7 운영, 차로별 GPU 워크스테이션 대체

Phase 1 · 현재 결과

13개 중 8개 모델 포팅 완료, 재학습 없이 FP16 → BF16 전환

YOLOv8n 3.6 ms · YOLOv8m 11 ms · D-FINE-M 16 ms · OCR 전체 29 ms (End-to-End, batch 1)

모델당 카드 PE 8개 중 2–4개만 사용

다음 단계

분류·Depth 모델 벤치마크

시스템 설계 워크숍, 실제 카메라 기반 차로 단위 연동

다차로 사이징 → PoC → 하드웨어 + 솔루션 사업 협력

Phase 0–1만으로 하드웨어 결정 전에 모델 단위 검증 근거를 무상으로 확보했습니다.

© 2026 FuriosaAI Inc.

시작하기: 첫 미팅에 준비할 것

01 모델 목록과 프레임워크·파일 형식 (PyTorch 등)

02 입력 사양: 해상도, 정적/동적 형태, 배치

03 목표 SLO: 지연, 처리량(스트림 × FPS), 정확도 허용 범위

04 소량의 대표 샘플 데이터

05 배포 제약: 현장 유형, 전력·랙 공간, 현장 수

시작 절차 3단계

1 FuriosaAI 사업개발팀 / 총판 문의

2 NDA 체결 및 Phase 0 사전 검토 착수

3 리모트 평가 서버 제공 — Phase 1 시작

문의: 김진수 상무 / jinsu.kim@furiosa.ai

© 2026 FuriosaAI Inc.

국내 대표 기업들과 서비스·인프라 배포를 확대

클라우드 · 통신 · 파운데이션 모델 · AI 서비스 · 데이터센터

SAMSUNG SDS

NPUaaS 상용화
RNGD 기반 국내 최초 NPUaaS 상용 서비스

LG U+

제품 출시
기업 고객 대상 소버린 AI 어플라이언스 배포

LG AI Research

모델 최적화
엔터프라이즈급 배포를 위한 AI 모델 최적화

upstage

공동 상용화
Solar 모델–하드웨어 통합 솔루션 공동 상용화

MEGAZONE CLOUD

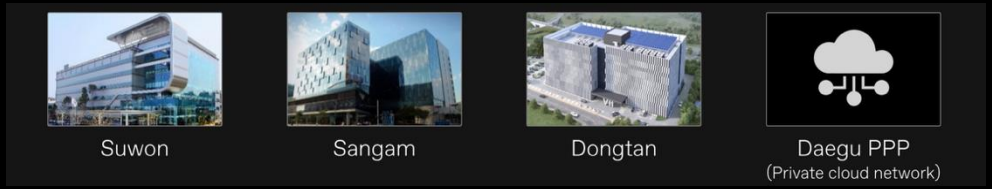
인프라 배포
국내외 데이터센터에 소버린 AI 스택 배포

Samsung SDS — RNGD 기반 국내 첫 NPUaaS, 서비스 오픈

Service	NPUaaS 서비스 오픈 (2026.7.20) RNGD VM을 Accelerated Server로 제공
Deployment	GDS 데이터센터
Adoption	VM 단위로 시작 구축 전 검증부터 상용 확장까지

인스턴스	vCore	Mem(GB)	RNGD
n1v8r1	8	106	1
n1v16r2	16	212	2
n1v32r4	32	424	4
n1v64r8	64	848	8

상용 서비스, 하드웨어 구매 없이 클라우드에서 즉시 검증하고 확장



RNGD VM (26.7 First NPUaaS among Korean CSPs)

Daum · Upstage · FURIOSA — Solar 기반 AI Summary 서비스

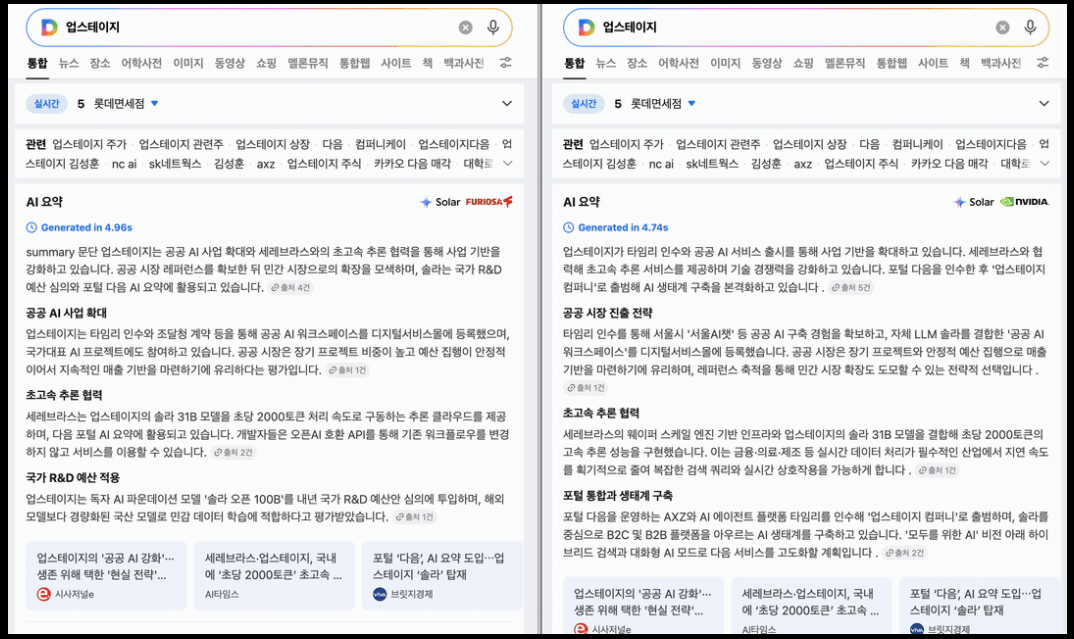
상용 서비스 오픈, 서비스 · 모델 · NPU 전 계층을 국산 기술로 구성

Full Stack
Daum · Solar Pro 3 · RNGD

Infrastructure
3개 서버 노드 · RNGD 24개

Service Scale
일 약 5억 토큰

Economics
현재 최소 1.5배 더 효율적
TCO 최대 50% 절감 목표



Furiosa Access: RNGD 평가 및 검증을 위한 Reference 환경





8× RNGD

Locations

Seoul	KOR
Bay Area	USA
Lisbon	PRT
Johor Bahru	MYS

160
NXT RNGD Servers

1280
RNGD Cards

5
Standard Clusters

Partners

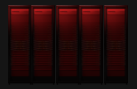
OCP ACCELERATED INFRASTRUCTURE SOLUTIONS CENTER
EQUINIX

© 2026 FuriosaAI, Inc. · Confidential

차세대 AI Workload를 위한 FuriosaAI의 제품 확장

2023 → 2026 → 2028

Hyperscaler Class



Gen 3

Enterprise / Datacenter



RNGD NXT Server 1
PCIe Gen 5



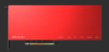
NXT RNGD Server 2
PCIe Gen 6 + 800G



Gen 3



RNGD
48 GB / 180 W / Jan 2026 MP



RNGD 64GB
64 GB / 180 W / Q1 2027 MP



RNGD X
128 GB / 350 W

Edge AI / Physical AI



Gen 1 Vision NPU



RNGD S



Gen 3

Gen 1 Gen 2 Next Gen

© 2026 FuriosaAI, Inc. · Confidential



면책 조항 및 추가 정보

본 프레젠테이션(이하 "본 프레젠테이션")은 FuriosaAI, Inc.(그 계열사를 포함하여 이하 "FuriosaAI")를 대신하여 작성되었으며, 본 문서에 기술된 기회(이하 "본 기회")를 검토할 목적으로 수신인의 사용을 위해서만 제공됩니다. 본 프레젠테이션은 정보 제공 만을 목적으로 하며, 본 기회와 관련되었는지 여부와 무관하게 어떠한 관할권에서도 어떠한 자에 대하여 증권 또는 자산의 매도 청약이나 매수 청약의 권유를 구성하지 않으며, 어떠한 계약의 근거도 되지 않습니다. 본 프레젠테이션의 제공은 FuriosaAI 또는 그 자산·사업에 대한 투자와 관련한 투자 자문, 금융 자문 또는 추천으로 간주되어서는 안 되며, 해당 투자가 수신인에게 적합한 투자임을 의미하지도 않습니다. 본 프레젠테이션은 수신인이 본 기회를 검토하거나 이에 참여함에 있어 필요로 할 수 있는 모든 정보를 포함하고 있음을 표방하지 않습니다. 본 문서에 포함된 정보는 기밀이며 수신인만을 위한 것입니다. 본 프레젠테이션에 참석하거나 이를 수령함으로써, 수신인은 본 프레젠테이션 및 본 기회에 대한 추가 검토와 관련하여 서면 또는 구두로 제공되는 정보를 기밀로 유지하고, FuriosaAI의 사전 서면 동의 없이 이를 어떠한 자에게도 서면 또는 구두로 복제, 전송, 배포, 공개 또는 제공하지 않을 것에 동의합니다. 본 프레젠테이션은 본 문서에 표시된 일자 기준 FuriosaAI의 현재 견해를 표현하는 진술을 포함합니다. 본 프레젠테이션에는 "예상", "믿음", "예산", "통제", "추정", "의도", "전망", "예정", "목표" 등의 미래예측 표현으로 식별될 수 있는, 본 프레젠테이션 일자 현재의 장래 사건에 대한 FuriosaAI의 견해를 구성하는 미래예측 진술, 의견 및/또는 추정이 포함되어 있습니다. 이러한 미래예측 진술, 의견 및/또는 추정은 미래 성과를 보장하지 않으며, 사업 계획에 기술된 사항, 시장 상황 및 운영 요인을 포함하되 이에 국한되지 않는 위험과 불확실성의 영향을 받습니다. 실제 사건, 결과 또는 성과는 그러한 미래예측 진술에 반영되거나 예상된 것과 중대하게 다를 수 있습니다. 본 문서에 제시되거나 달리 제공된 과거 성과 정보는 미래 결과에 대한 보장이나 지표가 아니며, 그러한 이유로 이에 의존해서는 안 됩니다. 제공된 정보의 정확성 또는 완전성에 대하여 명시적, 묵시적 또는 법령상의 어떠한 종류의 진술이나 보증도 이루어지지 않으며, FuriosaAI는 본 문서에 제시된 정보의 오류 또는 누락과, 제공된 정보의 사용·오용 또는 그에 대한 신뢰로 인하여 발생하는 손실 또는 손해(이익 손실 및 기타 직접적·결과적 손해를 포함하되 이에 국한되지 않음)에 대한 책임을 어떠한 근거로도 명시적으로 부인합니다. FuriosaAI와 그 이사, 임원, 직원, 자문인 및 기타 어떠한 자도 본 프레젠테이션 또는 그 내용의 사용으로부터 직접 또는 간접적으로 발생하거나 이와 관련하여 발생하는 오류, 누락 또는 손실에 대하여 어떠한 책임도 지지 않습니다. 본 프레젠테이션에 포함된 정보는 일반적인 사업, 경제, 시장, 규제 및 금융 여건을 포함한(이에 국한되지 않음) 여러 요인에 따라 사전 통지 없이 언제든지 변경될 수 있습니다. FuriosaAI는 추가 정보를 제공하거나 본 프레젠테이션을 보완·수정·갱신하거나 인지 여부와 무관하게 부정확한 사항을 정정할 의무를 부담하지 않습니다. 수신인은 투자 결정을 내리기 전에 FuriosaAI 및 제공된 모든 정보에 대하여 독자적인 분석과 실사를 수행하고 법률·재무·세무 자문인과 상의할 것이 권고되며 그렇게 할 것으로 기대됩니다. 미국 증권거래위원회 및 어느 국가, 주 또는 기타 관할권의 증권 규제 당국도 본 프레젠테이션의 정확성 또는 적정성에 대하여 판단한 바 없습니다. 본 프레젠테이션의 배포는 일부 관할권에서 법률에 의하여 제한될 수 있으며, 이에 따라 수신인은 자신이 거주하거나 사업을 영위하는 모든 관할권에서 법적 제한을 위반하지 않고 본 프레젠테이션을 수령할 수 있음을 진술합니다. 수신인은 FuriosaAI에 대한 독자적인 평가를 수행할 지식, 경험 및 능력을 보유하고 있음을 FuriosaAI에 인정하고 진술합니다. 본 프레젠테이션에 표시된 상표와 로고는 정보 제공 목적으로만 표시되며, 해당 상표와 로고는 각 소유자의 자산입니다. 본 프레젠테이션으로 인하여 FuriosaAI 또는 그 대리인과 수신인 또는 그 대리인 사이에 어떠한 법적 관계도 형성되지 않습니다. FuriosaAI는 언제든지 단독 재량으로 본 기회와 관련된 어느 당사자의 참여를 종료할 권리를 보유합니다. 본 기회, 본 프레젠테이션 및 그에 포함된 정보와 관련된 모든 연락, 문의 및 정보 요청은 FuriosaAI(Goun Whang, goun.whang@furiosa.ai)로 하시기 바랍니다. 본 프레젠테이션에 참석하거나 이를 수령함으로써, 수신인은 본 면책 조항에 명시된 조건을 인정하고 이에 동의합니다.