1. 서비스 개요

서버 한 대로 시작하는 사내 AI — NPU 서버 + 국산 LLM + API 플랫폼 일체형 패키지입니다.

패키지 구성

리벨리온 NPU 서버

ATOM-Max 서버 2종

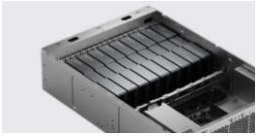
2U

동시 44명 · 부서 · PoC



4U

동시 88명 · 전사 도입



설치 · 3년 유지보수 포함

+

KT AI 모델

검증된 KT AI 모델

Mi:dm K 2.5 Pro

추론 에이전틱 국내 상위 128k 컨텍스트

K-Gemma

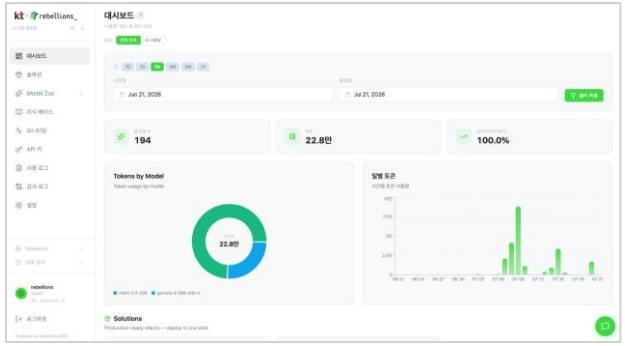
Gemma4 기반 튤 조율 성능 강화

사용권 3년 포함

+

API 플랫폼

RAG 지원 · LLM API · 모니터링



API 키 발급 → 업무 시스템 연동

타겟

AI 도입에 비용과 데이터 보안이 걸림돌인 공공기관, 금융, 의료, 제조 기업

2. 도입 이유 – 비용, 전력, 도입속도

외부 LLM 대비 연간 비용 약 60% 절감, 전력 25% 절감, 도입까지 Plug&Play로 설치 즉시 사용합니다.

1. 압도적 가성비

연간 AI 비용 (동시사용 88명 기준)

– 60%

Claude 팀 구독 ($110/인·월)

연 약 1.7억 원

KT NPU LLM Station (4U 한 대)

연 6,840만 원

팀 구독 : $110/사용자 + 한도 초과시 추가 과금
(환율 1,500원 · VAT 별도)

동급 국산 어플라이언스 대비 일시납 -24% ·3년 비용 -42%

구독 대비 연 약 1억 원 절감

2. 전력 효율

연간 전력

– 25%

일반 GPU 서버

3 ~ 4 kW

KT NPU LLM Station

2.5 ~ 3 kW

동급 GPU 서버 대비 14B LLM 모델 기준 비교

전기요금 걱정 없는 상시 구동

3. 구축 기간

도입에 걸리는 시간

Plug & Play

일반 GPU SI 구축 약 3개월

→ 설치만으로 완료

서버 + 모델 + 플랫폼 일체형 어플라이언스

약 1개월 내 도입 완료

3. 도입 이유 – 보안, K-AI 풀스택, 에이전트

데이터는 사내에 그대로, 스택 전체가 100% 국산, 업무 에이전트 3종 기본 탑재(예정)입니다.

4. 보안 — 사내 폐쇄망

사내 폐쇄망

NPU LLM Station

데이터는 사내에 그대로

✕ 외부 전송 차단

민감 정보 유출 우려 없음

망분리 · 규제 산업도 바로 도입 가능

5. K-AI 풀스택

100% 국산

- **국산 플랫폼** 운영 API Platform
- **국산 LLM 모델** Mi:dm K 2.5 Pro · K-gemma
- **국산 NPU 반도체** ATOM-Max

도입 자체가 소버린 AI

국산 풀스택

6. 업무 에이전트 (예정)

에이전트 탑재

1. **K-Claw** 범용 업무 자동화
2. **코딩** 사내 코드 안전 개발
3. **회의록** 회의 자동 요약 및 정리

KT AX 기술력으로 검증된 에이전트 확장

박스 하나로 시작하는 사내 AI 에이전트

4. 하드웨어 라인업

조직 규모에 맞춰 2U → 4U → Rebel(예정) 순으로 확장 가능합니다. (스케일업/스케일아웃)

2U 서버



ATOM-Max 카드 4장

AI 도입인원 약 100명

소규모 버티컬 AI · sLM · Vision AI

Mi:dm K 2.5 Pro · K-gemma · Llama 70B

부서 단위 도입

4U 서버



ATOM-Max 카드 8장

AI 도입인원 약 200명

전사 도입 · 중소형 모델 병렬 서비스

Mi:dm K 2.5 Pro · K-gemma · Llama 70B
bge-m3 — 여러 모델 동시 서빙

전사 단위 도입

Rebel 서버 예정



Rebel 카드 탑재

500B급 대형 모델

차세대 대형 모델 서비스

Minimax-m2.5 230B · gpt-oss-120B

대형 모델 수요 대응

5. VLM 영상 분석 교통 분야 활용

주요 VLM 모델 탑재를 통해 기존 사용 카메라와 연동 가능 (KT VLM 포함 예정)

사용 구조

영상 입력
기존 CCTV · 로봇 · 드론 연동

↓

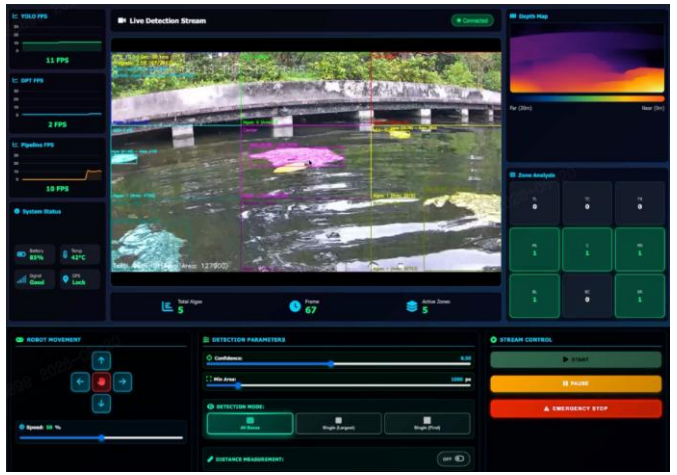
NPU LLM Station
VLM 영상 분석 · 상황 판단

↓

관제 제어
알림, 보고서 작성, 제어 명령

NPU LLM Station 통해 VLM 영상 분석

이동 카메라 : 순찰 로봇 · 순찰차



하천 부유 쓰레기 · 녹조를 인식해 로봇 이동 경로 안내

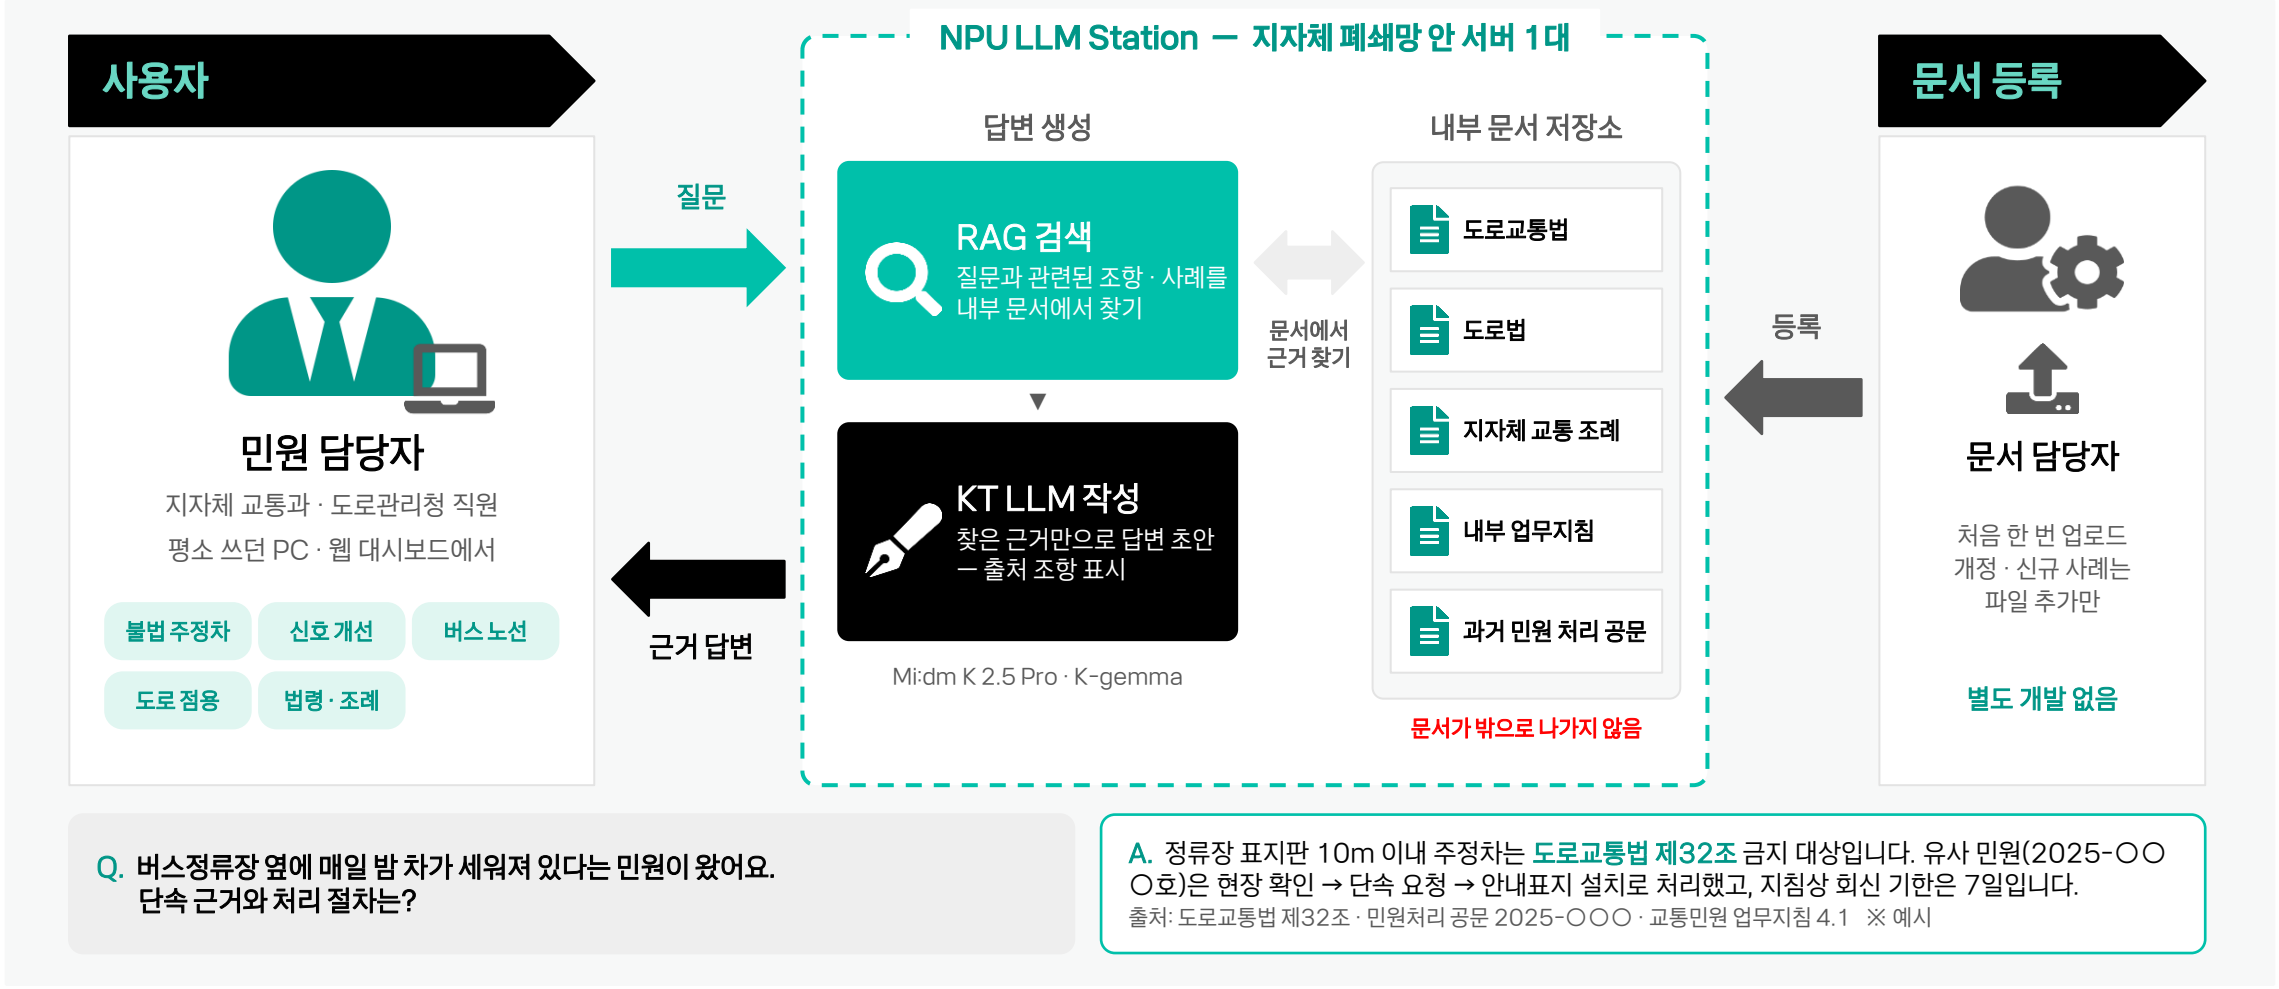
UAE 에코피스 수질 정화 로봇에 리벨리온 NPU 서버 적용

도로 순찰 영상 자동 점검

VLM 기반 특정 물건 상시 인식

6. RAG 활용 - 교통행정 · 민원 담당자

내부 문서를 올려두면, 담당자가 묻고, 그 문서에서 근거를 찾아 답합니다



Q. 버스정류장 옆에 매일 밤 차가 세워져 있다는 민원이 왔어요. 단속 근거와 처리 절차는?

A. 정류장 표지판 10m 이내 주정차는 **도로교통법 제32조** 금지 대상입니다. 유사 민원(2025-○○○호)은 현장 확인 → 단속 요청 → 안내표지 설치로 처리했고, 지침상 회신 기한은 7일입니다.

출처: 도로교통법 제32조 · 민원처리 공문 2025-○○○ · 교통민원 업무지침 4.1 ※ 예시

