Next AI Era Starts Here — Mobilint, Inc.

ITS 분야 NPU 적용과 GPU 솔루션 전환 지원 방안

모빌린트 [사업개발팀]

2026. 10

01

기업 및 제품 소개

Confidential. Please do not distribute.
Copyright © 2026 Mobilint, Inc. All Rights Reserved.

ABOUT US

모빌린트 소개

온디바이스부터 온프레미스 서버까지 자체 설계 NPU로 커버하는 팹리스 AI 반도체 기업

2019

모빌린트 설립

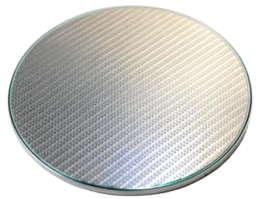
공동 창업자 3인 시작
Edge AI 추론용 NPU 개발 착수

mobilint

2021

첫 MPW Tape Out

첫 NPU 가속기칩
ARIES Tape-out



2025 - 2026

ARIES 및 REGULUS 양산 성공

본격 사업화 추진



현재

솔루션 개발 완료 및 상용화 성공

ARIES 기반 MLA100, MXM, MLA400 등
REGULUS 기반 USB, SOM, SBC 등

140명 +

임직원 수

국내 첫 AI SoC 검증 완료 및 양산 착수

PoC 진행 및 사업화 추진

100여개 협력사

Confidential. Please do not distribute. Copyright © 2026 Mobilint, Inc. All Rights Reserved.

제품과 기술

ARIES는 On-Prem, REGULUS는 On-Device를 담당

구분	공정	NPU 코어	연산 성능	소비 전력	적용
ARIES	삼성 14나노	8	80 TOPS	20 W	온프레미스 서버와 엣지 서버
REGULUS	TSMC 12나노	1	10 TOPS	3 W	로봇과 드론, 카메라, 키오스크



ARIES



REGULUS

단일 SDK로 모든 솔루션 구동

Runtime 실전 현장 총감독

- **Multi-Instance 병렬 실행:** 단일 NPU에서 여러 AI 모델 동시 구동
- C++/Python API로 Linux·Windows 환경에서 즉시 실행

Quantizer 핵심 요약 전문가

- **Mixed-Precision 자동 할당:** Layer별 민감도 분석으로 INT8/INT16 최적 배치
- **LLM Outlier 처리:** Activation 극단값 선별로 Edge NPU에서도 LLM 품질 보존

Compiler 수석 번역가 겸 네비게이션

- **490+ 모델 지원:** PyTorch·TensorFlow·ONNX를 .mxq 실행 파일로 변환
- **최적 경로 탐색:** AI 모델의 언어를 NPU가 알아듣는 언어로 변경, 가장 빠른 실행 경로 안내

NPU Core NPU 추론 특화 AI 엔진

- **Heterogeneous DNPU:** 다양한 AI 모델을 전담영역이 연산하여 전력 효율 극대화
- **유연한 스케일업 구조:** 단일 Core부터 Multi-chip까지 선형적 성능 증가

From AI Servers to On-Devices

서버 부터 Device까지, Mobilint가 제공하는 Full-Spectrum Edge AI 솔루션

Cloud
성능 🔴 비용 🔴 공간 🔴 전력 소비 🔴

Cloud NPU

On-Premises
성능 🔴 비용 🔴 공간 🔴 전력 소비 🔴

ARIES Chip

MLA400 PCIe Card

초고성능 AI 가속기



Server

HP, Dell Server

NPU 장착 서버





Edge Server
성능 🟠 비용 🟠 공간 🟠 전력 소비 🟠

ARIES Chip

MLA100 PCIe Card

초고성능 AI 가속기



ARIES Chip

MLX-A1 Edge AI Box

초고성능 NPU 기반 임베디드 AI



Edge Device
성능 🟠 비용 🟢 공간 🟢 전력 소비 🟢

ARIES Chip

MLA100 MXM

임베디드 시스템을 위한
고성능 AI 가속기



REGULUS Chip

MLM-1 SoM

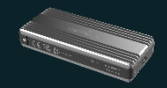
초소형 독립형 AI SoM



REGULUS Chip

MLD-R1 AI USB

초소형 AI USB



Small Device / Sensor
성능 🟢 비용 🟢 공간 🟢 전력 소비 🟢

🔴 High 🟠 Medium 🟢 Low

mobilint Confidential. Please do not distribute. Copyright © 2026 Mobilint, Inc. All Rights Reserved.

02

지원 모델과 구동 환경

Confidential. Please do not distribute.
Copyright © 2026 Mobilint, Inc. All Rights Reserved.

모빌린트 솔루션 지원 모델

Quantization Stack

Post-Training Quantization

GPTQ, LeanQuant, SVD-LLM, WLUT, PLUT, OptimizeLUT, Learnable LUT, Block-wise Rotation, Mobilint Quantizaitons 등

Quantization-Aware Training

Supervised QAT, Unsupervised QAT 등

Runtime Acceleration

Speculative Decoding, KV Cache-Centric Framework

Edge에서 400+개 AI 모델 지원

Any AI Model LLM · Vision · Action

Qwen2.5-Instruct	0.5B 1.5B 3B 7B
Qwen3	0.6B 1.7B 4B 8B
Llama-3.1-Instruct	8B
Llama-3.2-Instruct	1B 3B
EXAONE-3.5-Instruct	2.4B 7.8B
EXAONE-4.0	1.2B
EXAONE-Deep	2.4B 7.8B
YOLOv26	n s m l

Batched LLM

다중 요청 동시 처리

모델 지원 지속 확대
(Gemma4 포함 최신 모델 순차 지원 예정)

Model Zoo에서 확인 가능

* https://github.com/mobilint/mblt-model-zoo/tree/master/mblt_model_zoo

mobilint Confidential. Please do not distribute. Copyright © 2026 Mobilint, Inc. All Rights Reserved.

개발·구동 환경과 주요 이슈 대응

GPU에서 학습한 모델을 qb SDK로 컴파일해 NPU에서 구동하는 구조

대부분의 ITS 영상 모델은 재학습 없이 NPU 실행 파일로 변환

학습 완료 모델
PyTorch · TensorFlow · ONNX

→

qb Compiler · Quantizer
INT8 · INT16 혼합 양자화

→

NPU 실행 파일
단일 .mxq 파일로 배포

→

qb Runtime
C++ · Python API 연동

구분	지원 범위
딥러닝 프레임워크	PyTorch · TensorFlow · ONNX, 공개 모델 490여 종 검증 완료
운영체제	Linux(Ubuntu · Debian · Red Hat) · Windows
호스트 CPU	x86(Intel · AMD) · ARM
서버 · 폼팩터	Dell · HP · Supermicro · ASUS · Advantech 서버, PCIe · MXM · Box · SoM · USB

주요 이슈 대응

- INT8 · INT16 정수 연산 기반이라 변환 후 GPU 대비 정확도 검증 필요
- NPU 미지원 커스텀 연산자는 CPU 처리 또는 대체 연산으로 변환
- TensorRT 플러그인 등 CUDA 전용 코드는 qb Runtime API로 재작성
- 디코딩 · NMS 등 전후처리는 호스트 CPU 파이프라인으로 분리

Confidential. Please do not distribute.
Copyright © 2026 Mobilint, Inc. All Rights Reserved.

적용예시 | MLA100 기반

ITS 적용사례 - 영상 관제용 AI 서버

성남시





센터 영상 분석 서버

수많은 CCTV **영상을 자동 분석**해
교통 흐름·사고·혼잡을 실시간 파악하고
교통센터가 더 빠르고, 정확하게 도시 교통을 관리



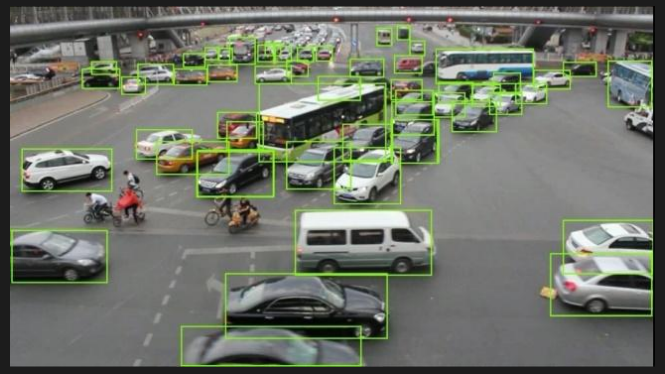
안양시





교차로 현장 영상 분석기

초저지연 신호 제어와 실시간 안전 감지를 위해
현장에서 직접 차량 인식, 차량 번호 OCR 등
AI 분석 수행



국내 최초 국산 AI 반도체를 활용해 제작된 Edge 컴퓨팅 장비



mobilint Confidential. Please do not distribute. Copyright © 2026 Mobilint, Inc. All Rights Reserved.

공공 교통 · 재난 관제 NPU 실증 사례

기존 CCTV는 그대로 두고 관제센터 서버에 NPU를 더해 AI 관제로 전환

전국 고속도로 CCTV 4,000채널을 국산 NPU 기반 AI 관제로 전환

한국도로공사 고속도로 AI 안전관제

과기정통부 · NIA 공공 AI CCTV 전환 사업

4,000+
고속도로 CCTV 채널

MLA400
AI 추론 서버 탑재

- 사고 · 고장 정차 · 역주행 · 보행자 · 낙하물을 실시간 1차 검지
- VLM이 전후 장면을 재확인해 오탐을 줄이고 상황보고서 자동 작성
- 기존 VMS · NVR · 네트워크를 유지한 채 NPU 서버만 추가
- 영상분석 파트너 인텔리빅스와 공동 수행

경남 산불 조기경보 · 재난 관제

산청 · 하동 · 함양 지역 상용 운영

2,000+
재난 관제 CCTV 채널

ARIES · REGULUS
서버 · 카메라 · 드론 적용

- NPU 탑재 고정형 카메라와 드론이 연기 · 불꽃을 현장에서 검지
- 지형 · 산림 · 기상 데이터를 결합해 확산 경로를 3D로 예측
- VLM이 육하원칙 상황보고서를 자동 생성해 초동 대응 단축
- 인텔리빅스 Gen AMS 관제 플랫폼에 모빌린트 NPU 적용

116.8억원	2026년 공공 AI CCTV 전환 사업	**18,100여 대**	사업 대상 공공 CCTV	**3개 기관**	경남 · 울산 · 한국도로공사 선정

과기정통부 · NIA 2026년 7월 발표 및 언론 보도 종합

mobilint Confidential. Please do not distribute. Copyright © 2026 Mobilint, Inc. All Rights Reserved.

ITS 업무별 NPU 적용 영역

관제센터 서버부터 노변 장비와 차량 단말까지 같은 SDK로 구동

센터 · 노변 · 차량 전 구간에 맞는 폼팩터를 단일 SDK로 공급

적용 위치	ITS 업무	모빌린트 제품
교통관제센터	CCTV 돌발상황 검지 · 교통량 분석 · VLM 상황보고	MLA400 · MLA100 AI 서버
교차로 · 노변	차량 · 보행자 검지, 스마트 교차로 신호 제어	MLX-A1 Edge AI Box
터널 · 도로 시설	화재 · 연기 · 낙하물 검지, 로봇 순찰	MLX-A1 · MLA100 MXM
단속 · 요금	번호판 인식(LPR) · 과속 · 신호위반 단속	MLA100 MXM · REGULUS
차량 · 대중교통	운전자 상태 · 승객 안전 모니터링, AI 카메라	REGULUS SoC · SBC · USB

ITS 적용 시 기술적 강점

- GPU 대비 소비전력 최대 93% 절감으로 노변 함체의 발열 · 전력 부담 완화
- 표준 PCIe 카드로 기존 x86 · ARM 서버와 관제 SW를 그대로 활용
- 클라우드 없이 현장에서 처리해 영상 개인정보의 외부 반출 차단
- -40~90°C 온도 사이클 700회를 통과한 산업용 신뢰성

Confidential. Please do not distribute. Copyright © 2026 Mobilint, Inc. All Rights Reserved.

03

NPU 전환 지원 방안

Confidential. Please do not distribute.
Copyright © 2026 Mobilint, Inc. All Rights Reserved.

GPU 솔루션의 NPU 전환 절차

모빌린트 엔지니어가 진단부터 양산 적용까지 단계별로 함께 수행

모델 파일과 샘플 영상만 있으면 2주 안에 전환 가능성 진단

01 전환 진단

예상 기간 1~2주

모빌린트 지원

모델 구조 · 연산자 지원 여부 분석, NPU 성능 예측

수요기업 준비

모델 파일(ONNX 등), 목표 FPS · 채널 수

02 모델 변환 · 최적화

예상 기간 1~4주

모빌린트 지원

qb 컴파일 · 양자화, 정확도 손실 최소화

수요기업 준비

양자화 보정용 샘플 이미지 · 영상

03 성능 · 정확도 검증

예상 기간 1~2주

모빌린트 지원

GPU 대비 정확도 · 처리량 비교 리포트 제공

수요기업 준비

정확도 판정 기준과 테스트셋 합의

04 시스템 통합 · PoC

예상 기간 1~3개월

모빌린트 지원

런타임 연동 기술지원, 평가 장비 제공

수요기업 준비

관제 SW 연동, 현장 시험 환경 마련

05 현장 적용 · 양산

예상 기간 협의

모빌린트 지원

양산 제품 공급, SDK 업데이트 · 유지보수

수요기업 준비

납품 사양 확정, 인증 · 조달 절차

Confidential. Please do not distribute.
Copyright © 2026 Mobilint, Inc. All Rights Reserved.

전환 소요 기간과 지원 범위

모델 복잡도와 시스템 통합 범위로 기간을 산정하고 초기 진단은 지원

전환 진단과 평가 장비 대여를 통한 효율으로 지원

전환 유형	예시	예상 기간
공개 모델 그대로 사용	YOLO 계열 차량 · 보행자 검지	1~2주
커스텀 학습 모델	자체 학습 검지 모델, 번호판 OCR	2~4주
다중 모델 파이프라인	검지 · 추적 · 재인식, VLM 연동	4~8주
현장 PoC · 시스템 통합	관제 SW 연동, 현장 시험 운영	1~3개월

기간 산정 조건은 모델 수, NPU 미지원 연산자 비중, 정확도 기준, 목표 채널 수, 기존 SW 연동 범위

기본 지원

- 전환 가능성 진단과 성능 예측 리포트
- qb SDK · Model Zoo · 기술문서 제공
- 평가 장비 대여 (MLA100 PCIe · MLX-A1)
- 엔지니어 기술 상담 · 개발자 교육

유상 지원

- 커스텀 모델 최적화 · 연산자 개발
- 시스템 통합과 현장 PoC 상주 지원
- 양산 장비 공급 (PCIe 카드 · AI 서버 · Box)
- 장기 유지보수 · 기술지원 계약

Confidential. Please do not distribute.
Copyright © 2026 Mobilint, Inc. All Rights Reserved.

04

ITS 협력 방안

Confidential. Please do not distribute.
Copyright © 2026 Mobilint, Inc. All Rights Reserved.

ITS 분야 희망 협력 방안

협회 회원사와 함께 GPU 기반 ITS 솔루션의 국산 NPU 전환 레퍼런스 확대

솔루션 기업 · 장비 제조사 · 운영기관과 공동 레퍼런스 구축

ITS 솔루션 기업

영상분석 · 교통관제 SW

협력 분야

돌발상황 검지 · LPR · 교통량 분석 모델의 NPU 포팅

협력 방식

공동 PoC, NPU 탑재 번들 제품 공동 출시

장비 · 제어기 제조사

노변 장비 · Edge 함체 · AI 카메라

협력 분야

스마트 교차로 제어기와 AI 카메라에 NPU 모듈 내장

협력 방식

MXM · SoM 기반 레퍼런스 보드 공동 설계, 양산 공급

운영기관 · 지자체 · SI

교통센터 · 도로 · 터널 관제

협력 분야

관제센터 GPU 서버의 NPU 서버 전환

협력 방식

정부 전환지원 사업 공동 컨소시엄, 실증 사이트 운영

ITS Korea와의 협력 제안 회원사 대상 NPU 전환 진단 데이 · 기술 세미나 정례 운영과 공동 실증 과제 기획

Confidential. Please do not distribute. Copyright © 2026 Mobilint, Inc. All Rights Reserved.


모빌린트는 고성능·저전력 NPU 기술력을 바탕으로
대한민국의 시스템 반도체 경쟁력을 강화하여
글로벌 AI 반도체 리더로 도약하겠습니다


AI STARTS HERE
WITH MOBILINT
mobilint