rebellions_



리벨리온, AI 인프라의 새로운 기준

Redefining AI Inference Infrastructure

© 2026 Rebellions Inc. All rights reserved.

Disclaimer

The information, analysis, projections, numbers and other material presented herein are provided for informational purposes only and should not be relied upon as investment, legal, or business advice. All content is presented on an "as is" basis, without any representations, warranties, or guarantees of any kind by Rebellions, Inc.("Rebellions"), whether express or implied, including but not limited to accuracy, completeness, timeliness, or fitness for any particular purpose. Rebellions reserves the right to make corrections, modifications, enhancements, improvements, and any other changes to this document, at any time without notice.

Neither Rebellions nor any of its affiliates, officers, employees, or representatives shall bear any responsibility or liability whatsoever for any errors, omissions, or consequences arising from the use of or reliance upon any information contained herein. Any recipients should conduct their own due diligence before making any decisions based on this information.





Agenda

- Rebellions 소개
- ATOM-Max 소개
- Rebel100 소개
- Q&A

© 2026 Rebellions Inc. All rights reserved.

리벨리온 회사 소개

리벨리온은 대한민국 소버린 AI를 이끄는 인공지능 반도체 전문기업 입니다.

Company Profile

사업영역	• AI반도체(NPU) 설계
설립일	• 2020년 9월 1일
본사	• 경기도 성남시 분당구 정자일로 156번길 R-TOWER
해외지사	• 미국 / 일본 / 사우디아라비아 / 싱가포르
전체인원	• 350+ 명 (2026년 9월 기준)
투자	• 6,400억원 Fund raised (프리IPO) • 누적 1.3조원(기업가치 3.4조 `26년 5월 기준)

Our Products

ATOM™-Max 상용화 완료	Rebel100 `26 하반기 출시 예정
SAMSUNG Foundry 5nm	SAMSUNG Foundry 4nm, HBM3e
	

Global investor

SAMSUNG · arm · PEGATRON · TEMASEK · korelya capital · WAED by aramco · Kindred Ventures · DGDV · TopTier

Key Deployments

kt cloud	kt	경상남도 GYEONGNAM	SK telecom A.X
AI 추론용 클라우드 서비스 출시	NPU LLM Station 출시	공공 AI CCTV 전환 사업 인프라 구축	전화 통화 요약 서비스 “에이닷” 적용

© 2026 Rebellions Inc. All rights reserved.

리벨리온 NPU 장점: 가성비

고객 서비스 평가 결과, GPU 대비 1.7~2.5배의 가성비를 보여주고 있습니다

Model	LLM -14B	이미지 분석 (ResNet)	객체 탐지 (YOLO)
L40s ATOM™-Max	<TPS> **1.7 x** 1279 2120	<FPS> **2.5 x** 25K 62K	<FPS/W> **1.9 x** 0.60 1.16
Use Cases	AI 엔드포인트 (고객 상담 챗봇 등)	안면 인식 서비스	오염물 탐지 서비스

© 2026 Rebellions Inc. All rights reserved.

리벨리온 NPU 장점: 제품 공급과 지원 체계

짧은 Lead Time 과 확실한 사후 기술지원을 보장합니다

제품 공급

서버 재고 사전 확보

계약 즉시 출고 가능한 재고 운영으로,
수개월 대기 없는 짧은 리드타임 보장

나라장터 등록

공공기관은 조달 프로세스를 통해 바로 구매 가능

국내 공급망

수출 규제·지정학 리스크의 영향 없이 안정적으로 공급

지원 체계

리벨리온 FDE 직접 지원

도입 설계부터 모델 최적화까지 제조사 엔지니어가 직접 지원

정기적인 SDK 업데이트

기술 문서와 Model Zoo를 GitHub에 공개,
월 1회 지속 업데이트 진행

공식 유지보수 파트너 · 전국 단위 온사이트 대응

© 2026 Rebellions Inc. All rights reserved.

리벨리온 NPU 장점: 최다 상용 Reference 보유

다양한 사례를 바탕으로 E2E 서비스 구동을 지원합니다

클라우드형 (NPUaaS)

kt cloud



국내 최초 공공 전용
NPU Server 출시

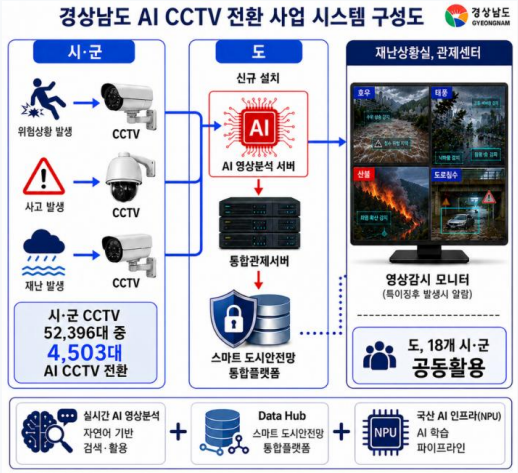
구축형 (On-Prem Appliance)

kt



NPU LLM 스테이션 출시

경상남도 GYEONGNAM JDONE



공공 AI CCTV 전환 사업
(4,500채널)

상용 서비스 운영 (In-house Production)

에이닷 (SK telecom)

리벨리온, SKT AI서비스 지원 확대
하루 40억 이상 토큰 처리



통화 요약 | 음성 합성 | AI 고객센터 | 미끼문자 탐지

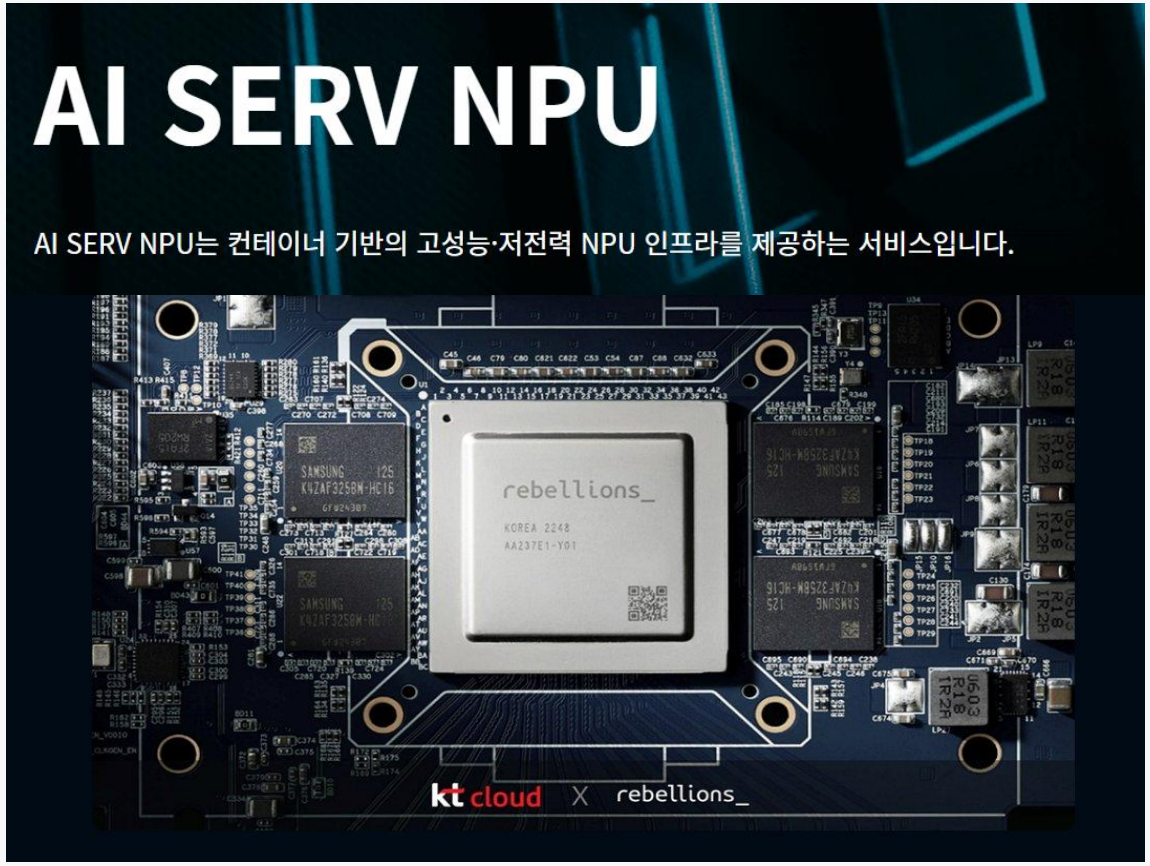
rebellions_

© 2026 Rebellions Inc. All rights reserved.

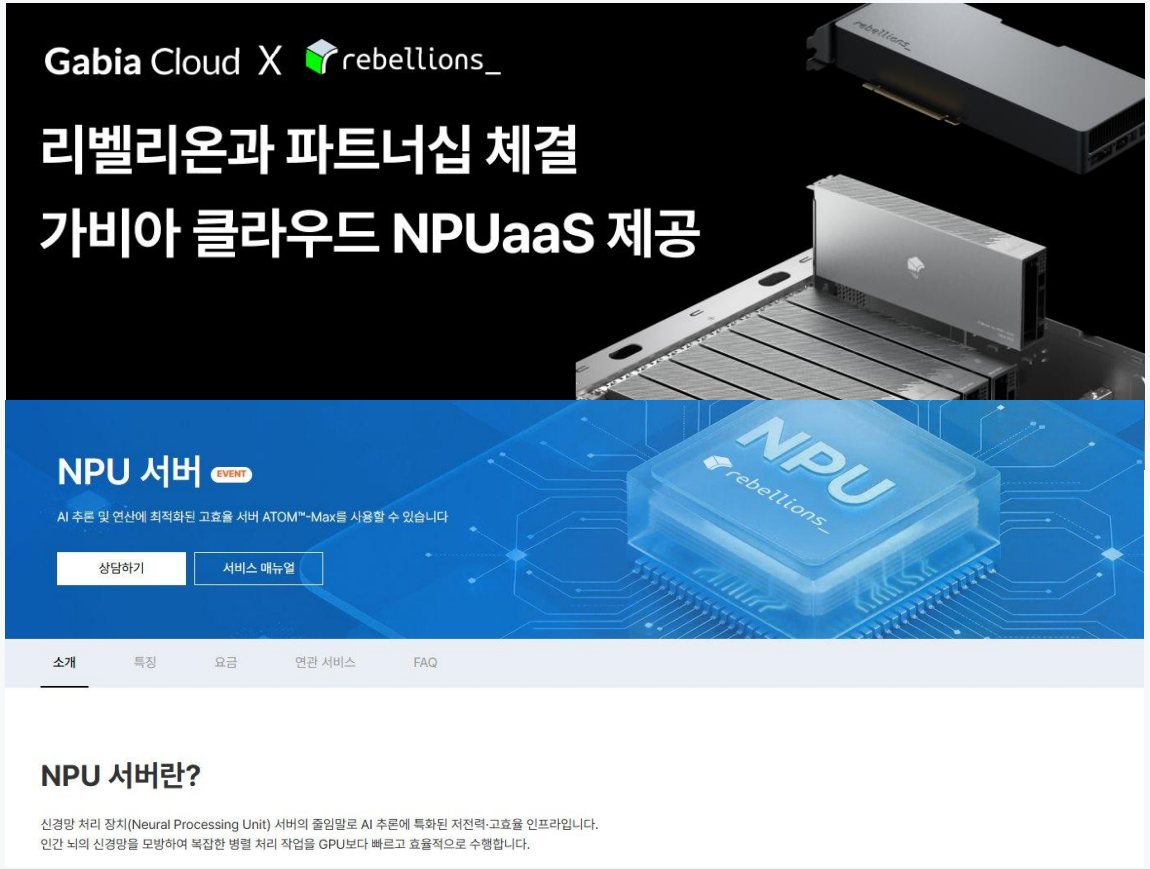
적용 사례: Cloud Service Provider

KT 클라우드, 가비아 클라우드에서 NPU Instance 의 활용이 즉시 가능합니다

kt cloud



gabia.cloud



© 2026 Rebellions Inc. All rights reserved.

적용 사례: LLM 기반 솔루션/서비스

KT NPU LLM Station 워트인텔리전스의 키워트, 몽골관세청의 RAG 기반 챗봇, SKT의 에이닷 에 도입되었습니다

KT NPU LLM Station

"NPU서버와 LLM,
에이전트를 통합 제공"



Wert Intelligence

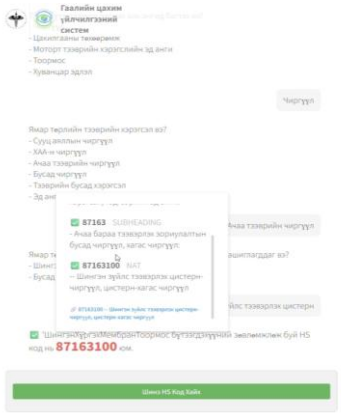
"국내 기술 기반 AI 풀스택
특허 기술문서 분류·요약 솔루션"

keywert



VIRNECT

LLM/RAG 기반 몽골 관세청
물품 분류 코드 AI 추천 챗봇



SK telecom

"하루 3~5천만
API Call 처리"

에이닷



© 2026 Rebellions Inc. All rights reserved.

적용 사례: VLM 기반 지능형 AI CCTV 솔루션

리벨리온의 NPU는 LG전자, 위시, 제이디원의 VLM 기반 지능형 AI CCTV 솔루션의 추론 인프라로 채택되고 있습니다

JDONE

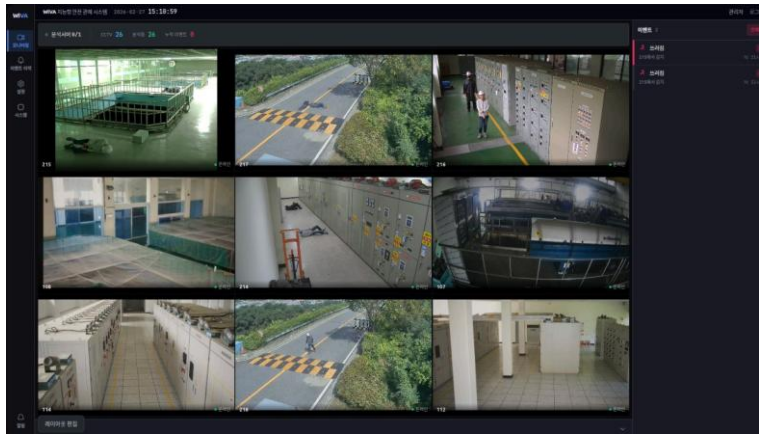
(서비스명) AI Eyes One



경상남도 GYEONGNAM ‘경남 도청 도입’

WISH ai creativity

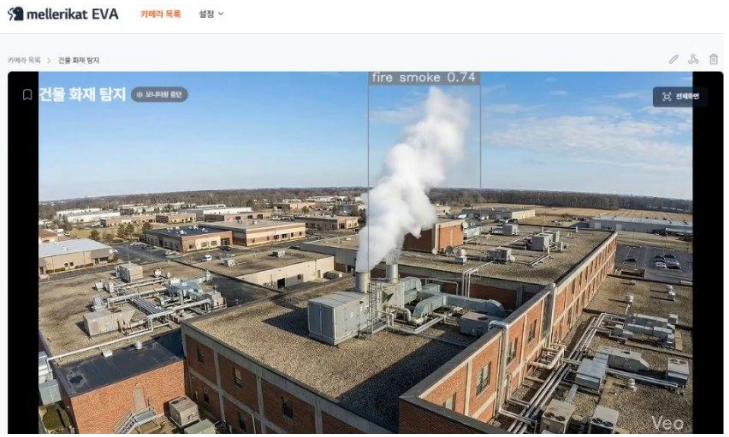
(서비스명) WISH Vision Agent



울산광역시 ‘울산광역시 도입’

LG전자 mellerikat

(서비스명) 멜러리캣 EVA



VLM(Vision Language Model) 기반 관제는 이제 GPU를 필요로 하지 않습니다.
리벨리온 NPU ATOM™-Max 단독으로, 세 파트너의 상용 서비스가 출시되어 있습니다.

© 2026 Rebellions Inc. All rights reserved.



ATOM-Max 소개

© 2026 Rebellions Inc. All rights reserved.

제품 특성: 카드 스펙

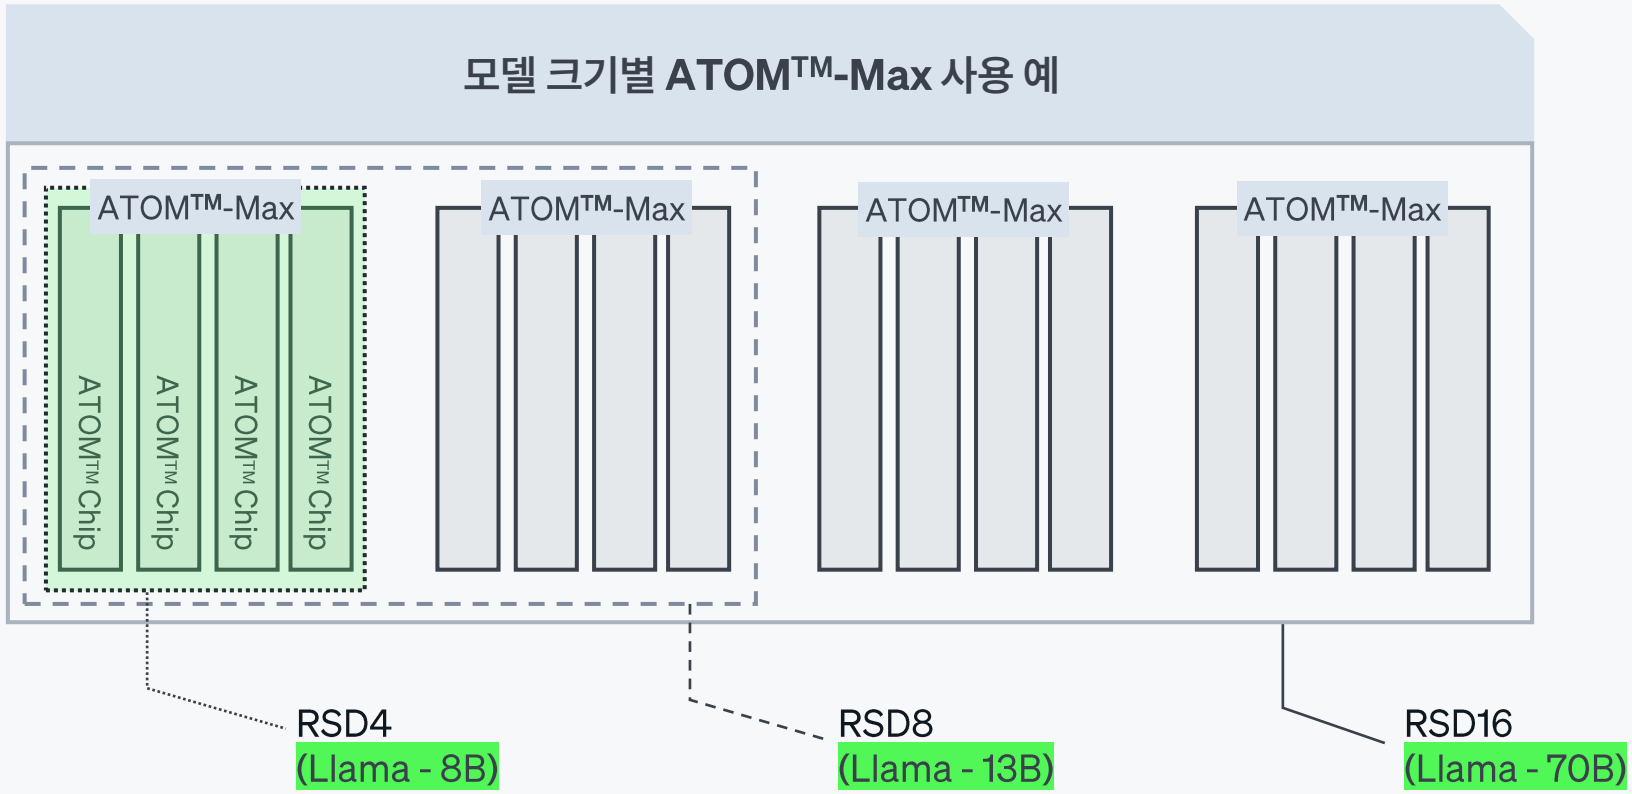
ATOM™-Max는 L40S 급의 스펙을 가지고 있습니다

Specification \ Chip		rebellions_	NVIDIA	NVIDIA	NVIDIA
		ATOM™-Max	L40S	A100	RTX A6000
Process Node		**Samsung 5nm**	TSMC 5nm	TSMC 7nm	Samsung 8nm
Compute Capacity	**FP8** (TFLOPS)	**–**	733	-	-
	FP16 (TFLOPS)	**128**	362	312	155
Memory	**Type / Size**	**GDDR6 64GB**	GDDR6 48GB	HBM2E 80GB	GDDR6 48GB
	Max BW (TB/sec)	**1 TB/s**	864 GB/s	1,935 GB/s	768 GB/s
Card	**Type**	**PCIe**	PCIe	PCIe	PCIe
	Power (TDP)	**350**	350	300	300

© 2026 Rebellions Inc. All rights reserved.

지원 모델 크기

ATOM™-Max는 최대 70B 모델의 추론을 지원합니다



멀티 카드 병렬 연산 기능(RSD)을 통해 모델 크기별 맞춤 운영 지원

© 2026 Rebellions Inc. All rights reserved.

ATOM™-Max Value Prop.

L40S 대비 저렴한 도입비용, 운영비용을 자랑합니다

2X

Lower CapEx

Cost per server

3X

More tokens

Per dollar

1.4X

Tokens per watt

Energy efficiency

** Based on LLM-8B, TTA 인증 결과*

© 2026 Rebellions Inc. All rights reserved.

ATOM™-Max Server (2U)

2U 서버는 산업 현장/전산실 랙 등 소규모 도입이 필요한 버티컬 AI 서비스(비전 AI, LLM 어시스턴트 등)에 적합합니다

기능	설명
Form Factor	2U (4x ATOM™ - Max Card)
CPU	1x EPYC 5th Gen
NPU	256GB GDDR6, 8TB/s
Network	10G 2Port * 1 ~ 2
Memory	768GB
Storage	1.92TB SSD * 2
Typical/ Max Power Consumption	Max 2kW
OS	Ubuntu, RHEL, AlmaLinux, RockyLinux



© 2026 Rebellions Inc. All rights reserved.

ATOM™-Max Server (4U)

4U 서버는 중소형 AI 모델 기반 규모감 있는 AI 서비스 트래픽 대응에 적합한 데이터 센터향 서버입니다

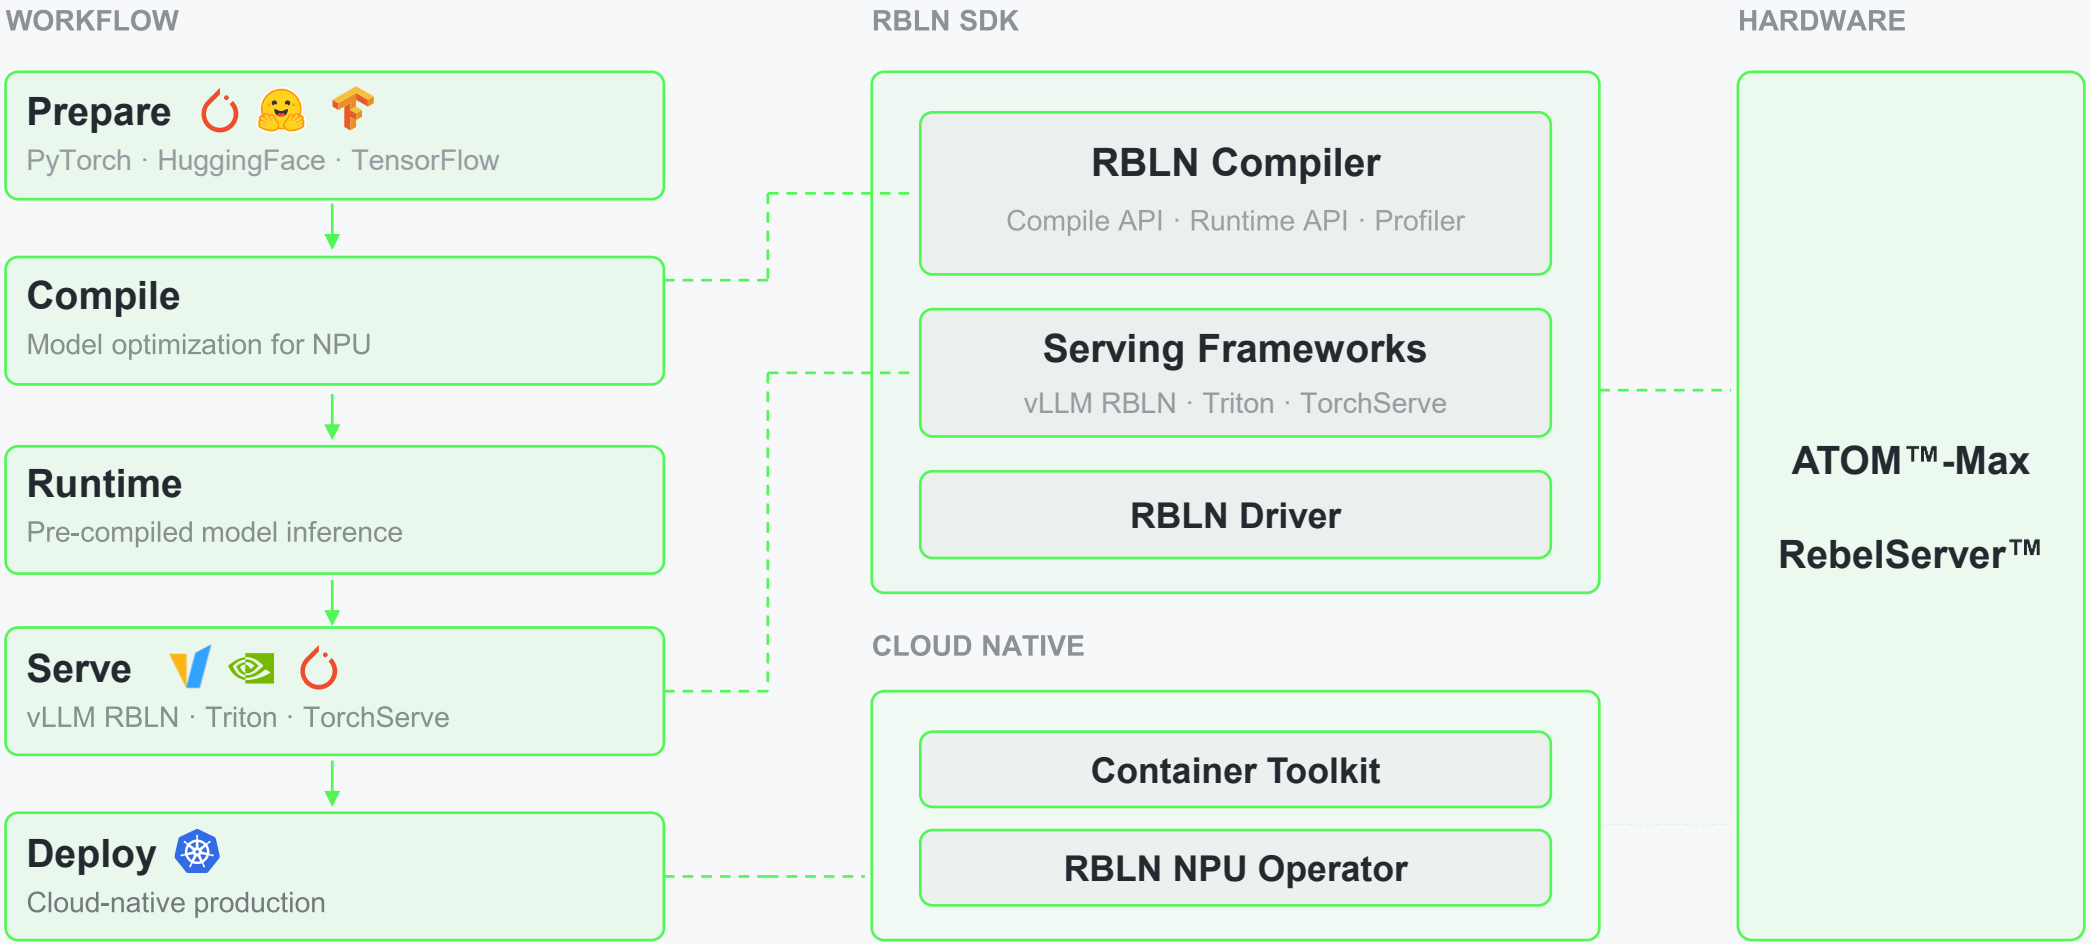
기능	설명
Form Factor	4U (8x ATOM™ - Max Card)
CPU	2x EPYC 5th Gen
NPU	512GB GDDR6, 8TB/s
Network	10G 2Port * 1 ~ 2
Memory	1.5TB / 2.3TB
Storage	1.92TB SSD * 2
Typical/ Max Power Consumption	Typical 3.4kW (Max ~4.3kW)
OS	Ubuntu, RHEL, AlmaLinux, RockyLinux



© 2026 Rebellions Inc. All rights reserved.

SDK 제공

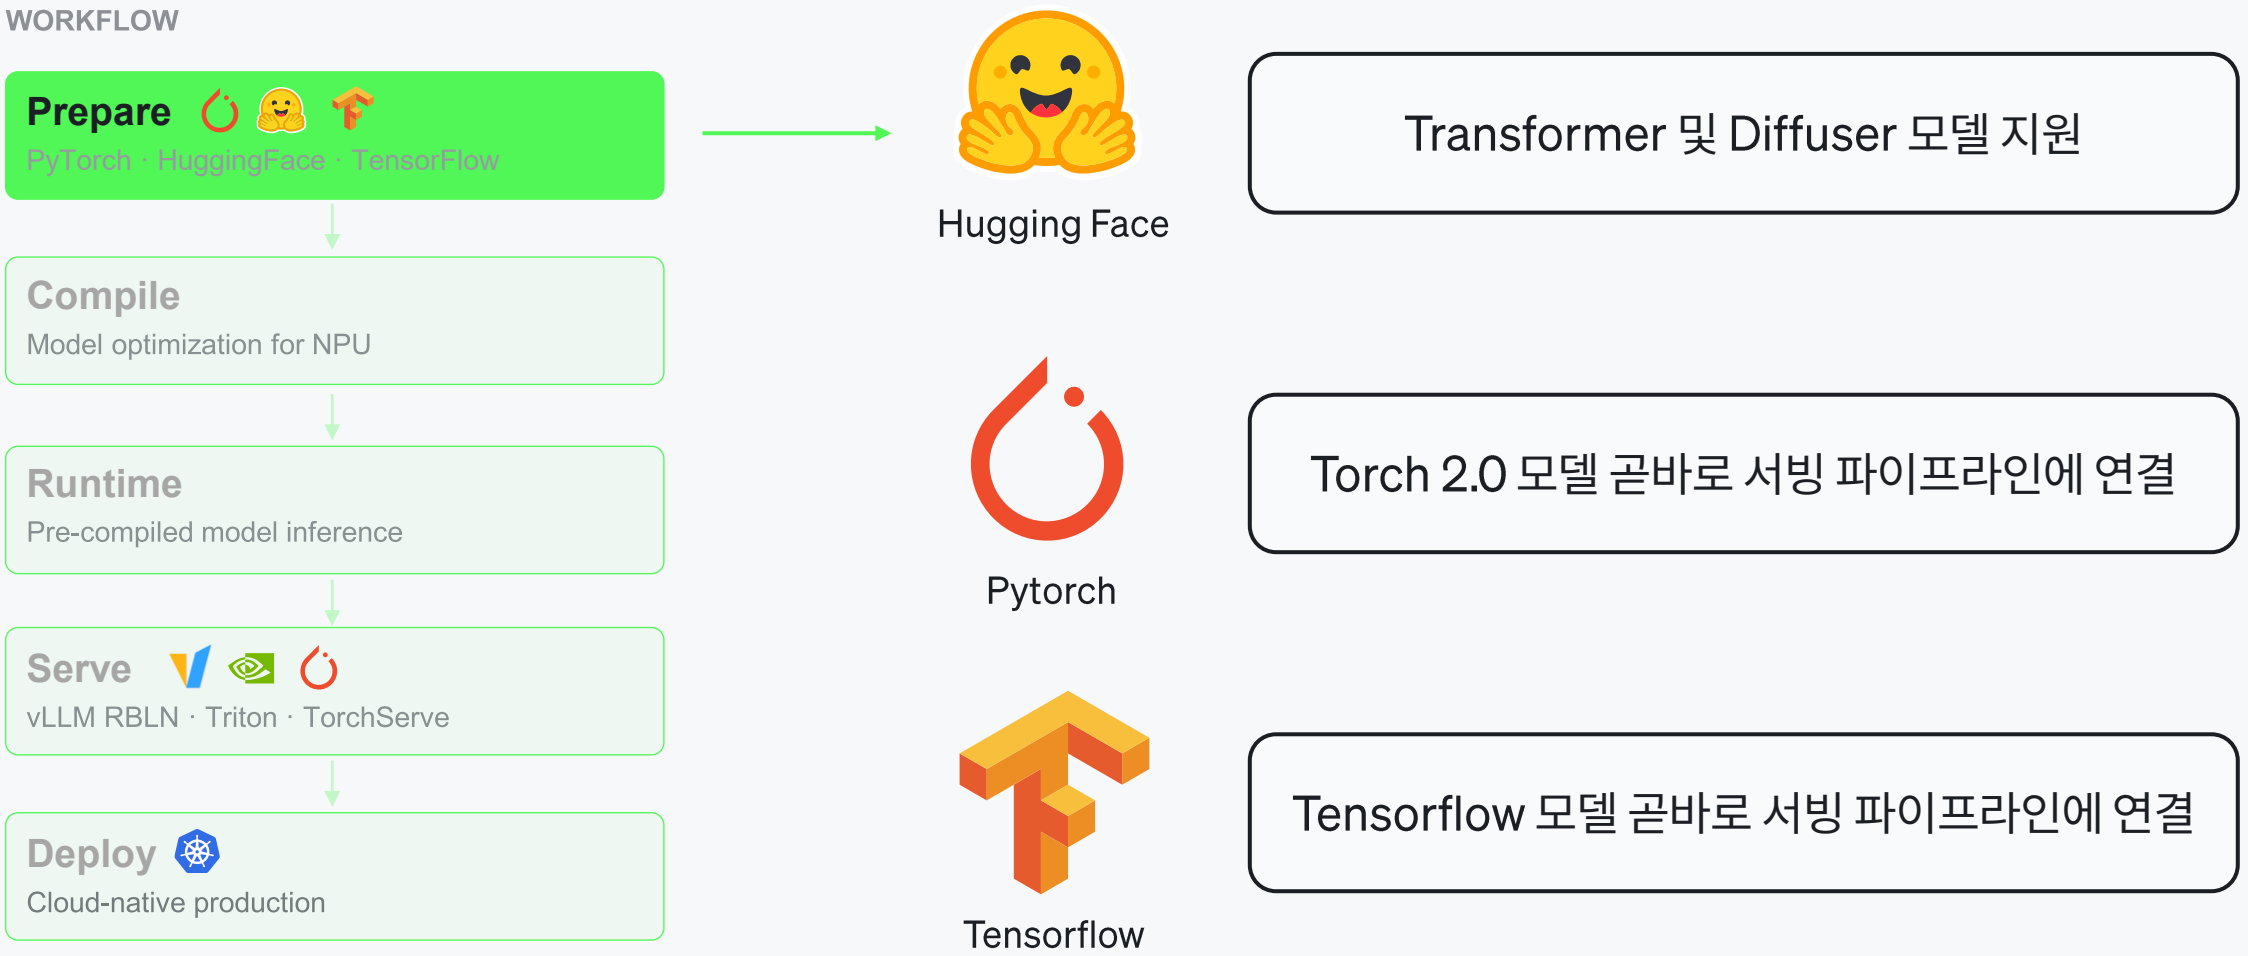
HW 구동에 필요한 Compiler 등 SDK 를 함께 제공합니다



© 2026 Rebellions Inc. All rights reserved.

AI 모델 사용

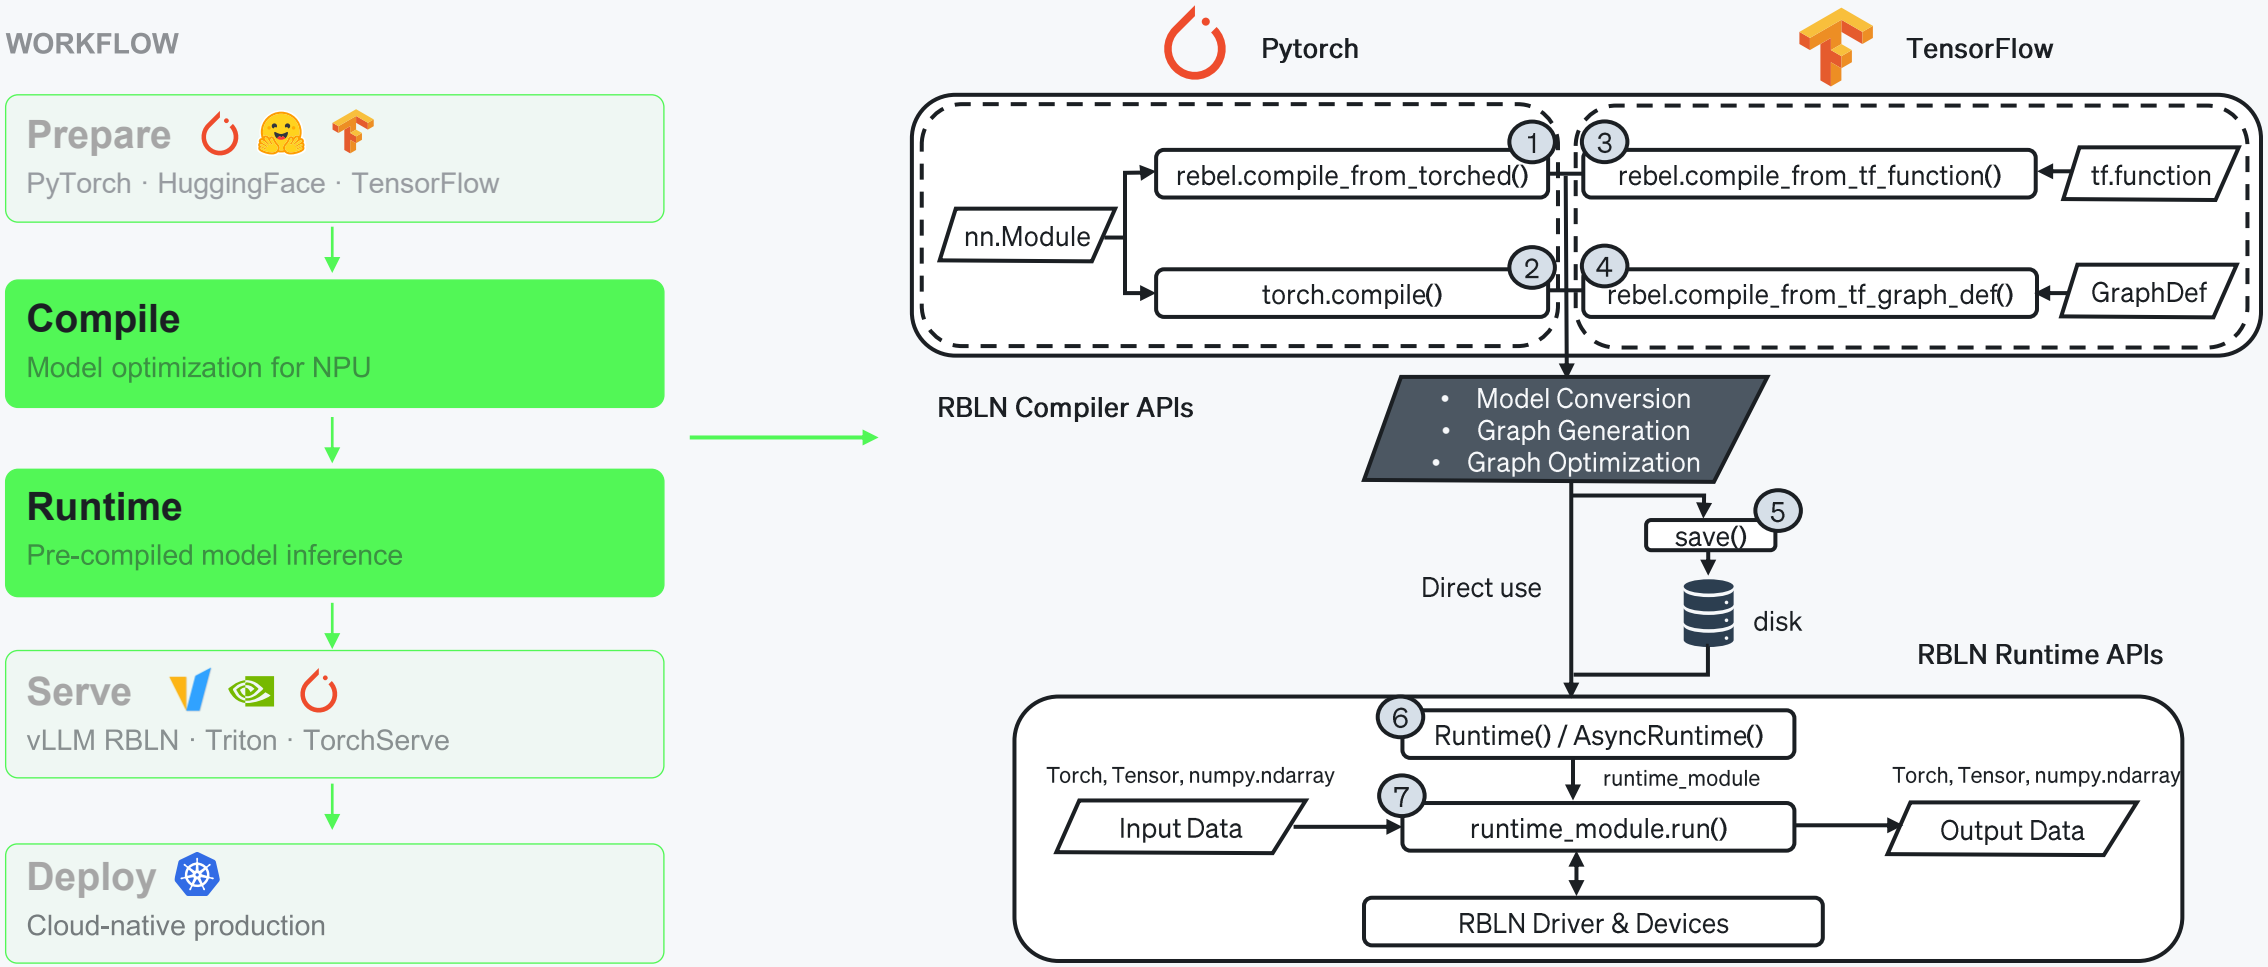
Hugging Face 와 Pytorch 의 모델은 별도의 변환 없이 바로 사용 가능합니다



© 2026 Rebellions Inc. All rights reserved.

Compiler 와 Runtime API

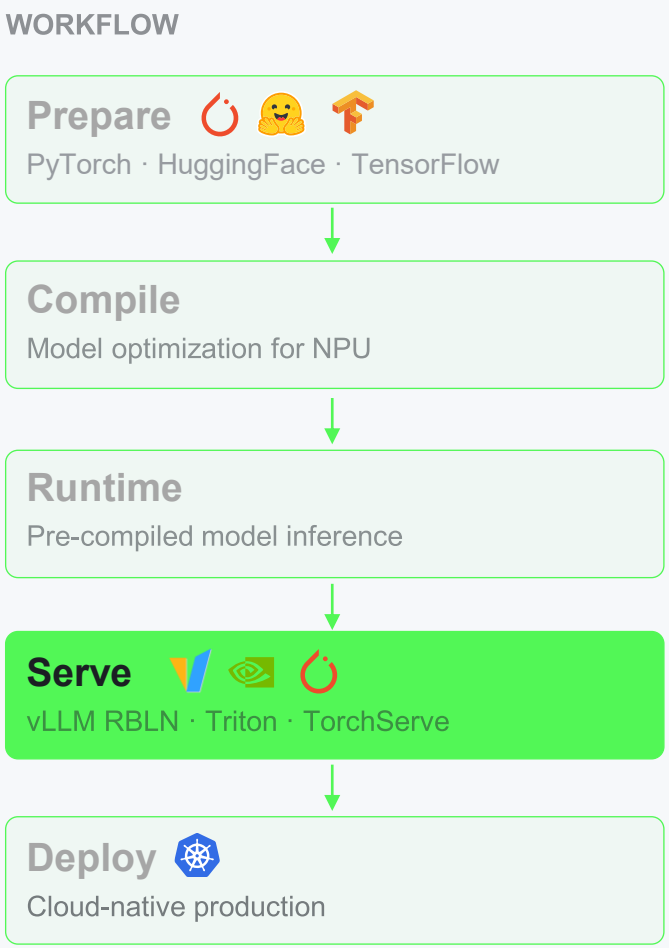
각 API 만 다운받아 활용하면 AI 모델의 즉각적인 추론이 가능합니다



© 2026 Rebellions Inc. All rights reserved.

vLLM 과 Triton

Open-source 의 표준 serving 을 지원합니다



vLLM × rebellions_

vLLM Community에서 공식 지원하는
vLLM용 하드웨어 플러그인을 제공합니다.
(Documentation Link)

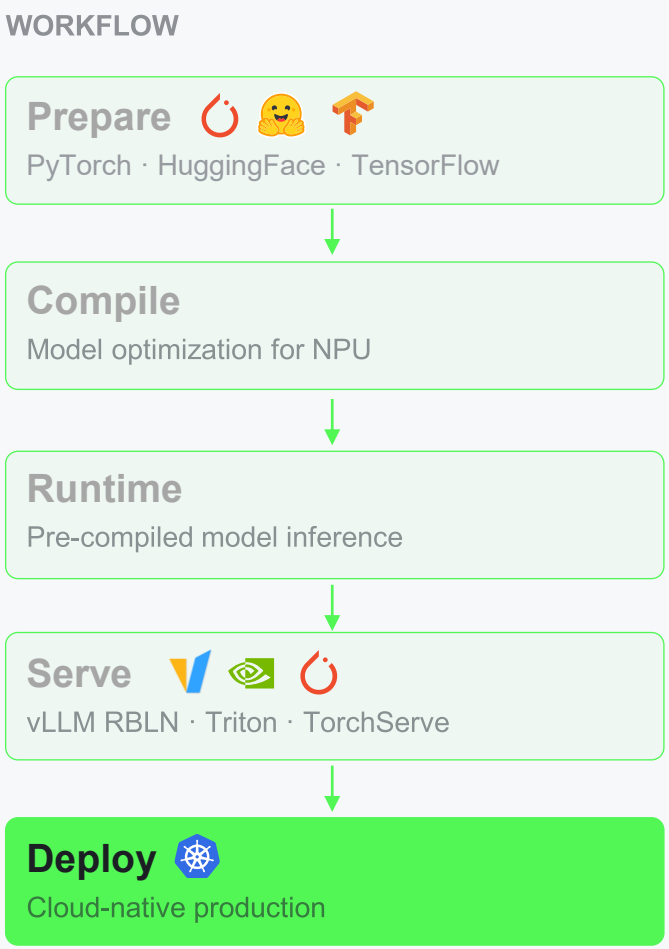
Triton Inference Server × rebellions_

기존 Triton Inference Server로 구축된
배포 환경을 그대로 이용할 수 있습니다.
(Documentation Link)

© 2026 Rebellions Inc. All rights reserved.

K8s 와 Redhat

Docker와 K8s 를 지원합니다



kubernetes

디바이스 플러그인, 노드 레이블, 메트릭 모니터링 툴을 자동 배포하며 쿠버네티스 환경 내 **NPU** 리소스를 통합 관리할 수 있습니다.
(Documentation Link)

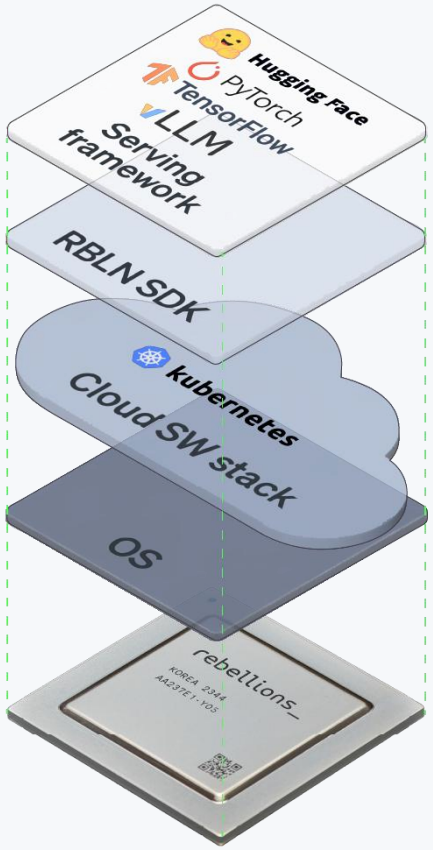
Red Hat × rebellions_

리벨리온 NPU는 Red Hat Enterprise Linux와 호환되며,
Red Hat OpenShift Certified 제품으로 공식 등록되어 있습니다.
(Red Hat Ecosystem Catalog Link)

© 2026 Rebellions Inc. All rights reserved.

SW Stack

가장 널리 쓰이는 업계 표준 AI 소프트웨어를, 가장 익숙한 워크플로우 그대로 지원합니다



* Experimental or limited support

RBLN Cloud Toolkit

NPU operator
Kubernetes plugin, metrics exporter, VFIO manager, device installer, node feature discovery

RBLN SDK

Compiler

Runtime

Profiler

Model Zoo
compatible with PyTorch, HuggingFace Optimum

vllm-rbln
customize/extend vLLM features for NPU

torch-rbln
Natively support PyTorch without model porting

triton-rbln *
Device plugin for Triton kernel programming

System management tools (rbln-smi, etc)
Kernel driver
Firmware

ready for deployment

vLLM official plugin

PyTorch out-of-tree extension

Cloud Platform

openstack. Red Hat kubernetes

Integration: Prometheus Grafana ceph Istio

AI Stack

PyTorch Hugging Face vLLM NVIDIA. TRITON INFERENCE SERVER

language: python™

OS Support

Ubuntu 22.04/24.04 RHEL 9.6/10.0.

© 2026 Rebellions Inc. All rights reserved.



Rebel100 소개

© 2026 Rebellions Inc. All rights reserved.

제품 특성: 카드 스펙

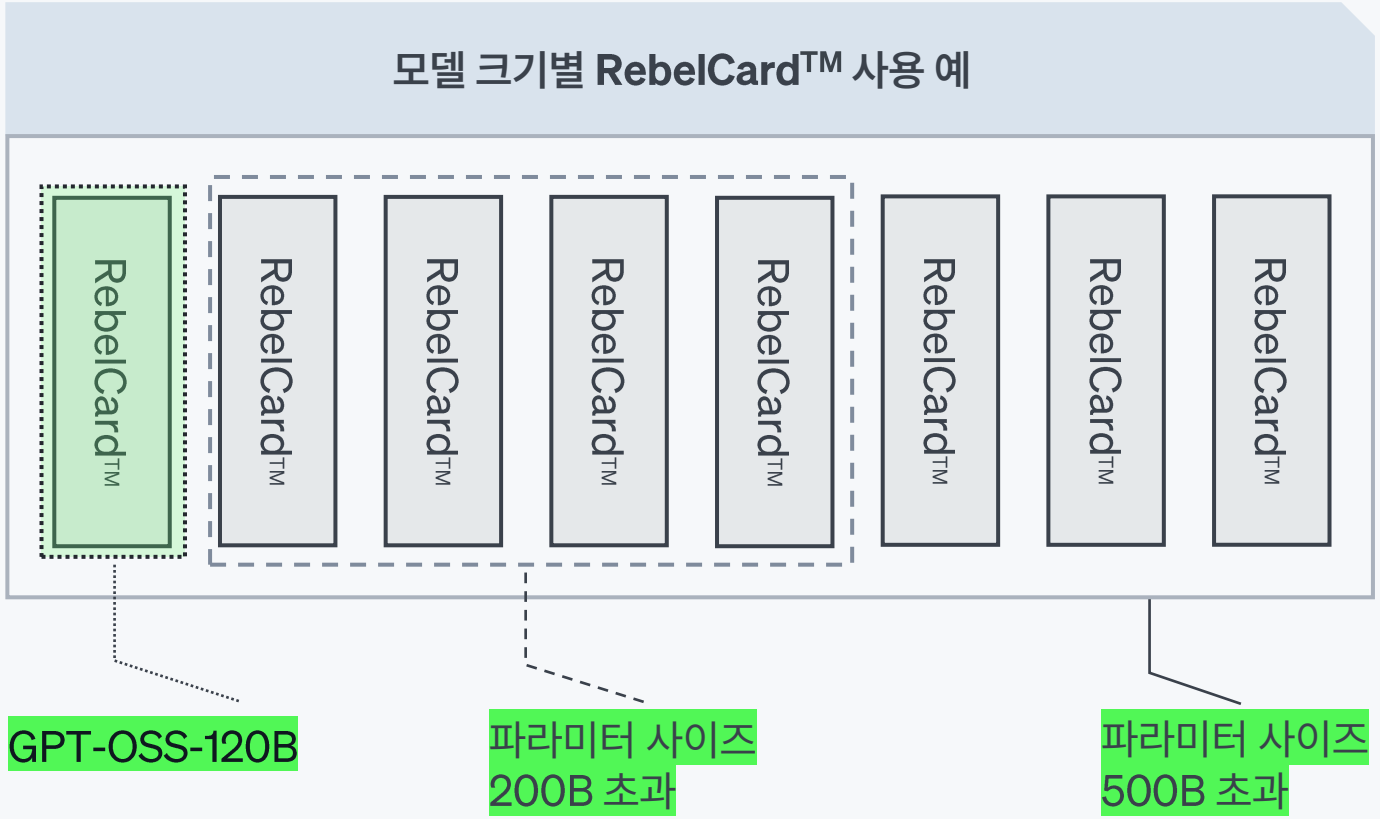
Rebel100은 H200 급의 스펙을 가지고 있습니다

Specification \ Chip		rebellions_	NVIDIA	NVIDIA	NVIDIA
		Rebel100 (4x chiplet)	H200	H100	B200
Process Node		**Samsung 4nm**	TSMC 4nm	TSMC 4nm	TSMC 4nm
Compute Capacity	**FP8** (TFLOPS)	**2,048**	1,980	1,513	4,500
	FP16 (TFLOPS)	**1,024**	990	757	2,250
Memory	**Type / Size**	**HBM3E 144GB**	HBM3E Up to 141 GB	HBM2E 80GB	HBM3E 180GB
	Max BW (TB/sec)	**4.8 TB/s**	4.8 TB/s	2.0 TB/s	7.7 TB/s
Card	**Type**	**PCIe**	SXM	PCIe	SXM
	Power (TDP)	**600**	700	300	1,000

© 2026 Rebellions Inc. All rights reserved.

지원 모델 크기

Rebel100은 500B+ 파라미터 모델의 추론을 지원합니다



멀티 카드 병렬 연산 기능(RSD)을 통해 모델 크기별 맞춤 운영 지원

© 2026 Rebellions Inc. All rights reserved.

Rebel100 Value Prop.

H200 대비 저렴한 도입비용, 운영비용을 자랑합니다

3X

Lower CapEx

Cost per rack

2.8X

More tokens

Per dollar

2.2X

Tokens per watt

Energy efficiency

** Based on gpt-oss-120B equivalent workload*

© 2026 Rebellions Inc. All rights reserved.

RebelServer™ (5U)

RebelServer™에는 카드 8장이 탑재되며 초대형 모델을 serving할 수 있습니다

Feature	Description
Form Factor	5U (8x RebelCard™ PCIe Gen 5 cards)
CPU	2x AMD EPYC 9355 [EPYC 5th Gen]
Memory[1]	Option1) 1.5TB (24x 64GB DDR5) Option2) 2.3TB (24x 96GB DDR5)
Disk	2x 1.92TB SATA SSD (SW RAID)
Network[2]	4x 400G 1-Port QSFP112-DD 1x 100G 2-Port QSFP56 1x 10G/25G 2-Port SFP28 (OCP 3.0)
PSU	6x 2700W
Typical/ Max Power Consumption[3]	4-6kW/7kW
Accelerator	8x RebelCard™
OS	Red Hat or Ubuntu (plus Rebel Software Stack)

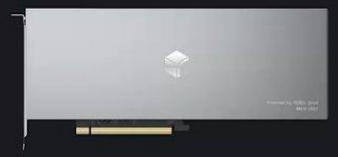


1) Subject to change based on customer requirements
2) SFP28 or RJ45 available depending on customer requirements
3) Theoretical maximum power consumption based on specifications. Actual power consumption will not exceed 7 kW, typically hovering around 4-6kW at most under practical workloads.

© 2026 Rebellions Inc. All rights reserved.

[RebelCard™ 1장 _ GPT-OSS-120B 서빙]

rebellions_



LIVE

Running GPT-OSS-120B on a RebelCard™ Single Card

COMPUTE (DENSE)	FP16	1,024 TFLOPS
	FP8	2,048 TFLOPS
MEMORY (HBM3E)	Capacity	144 GB
	Bandwidth	8 TB/s
CHIPLET INTERFACE (UCIE-A)	Speed	16 Gbps
	Throughput	1 TB/s/ch

OpenAI
GPT-OSS 120B

vLLM Paged/ Flash Attention

MoE MXFP4 (Quantized) FP16 (Activation)

vLLM in processing

Ready for Inference

Enter your prompt below or browse example prompts

Browse Example Prompts

✦ Auto Mode

Enter a prompt to run inference on Rebellions NPU

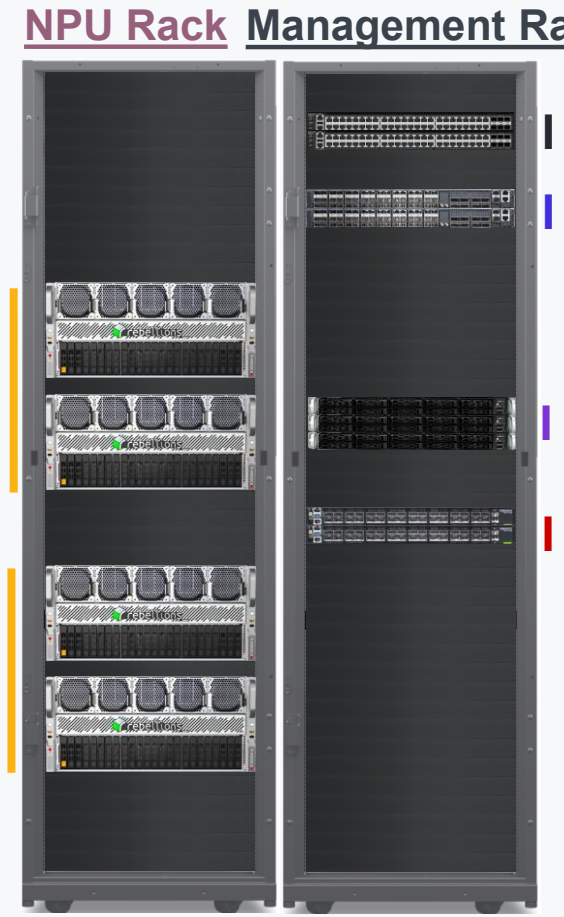
RebelRack 구성

Rack 구성을 통해 더 큰 모델의 구동을 지원합니다

Nodes
- 1, 2, or 4 NPU nodes

Software
- OS: RHEL, Ubuntu
- Rebel SW stack

Rack
- Standard 42RU data center rack



Out-of-band network
- 1GbE switch
- Cluster health monitoring
- BMC / IPMI / Provisioning

Front-end network
- 25G switch
- Cluster Orchestration
- Scales independent from comput e fabric

Compute fabric
- 800G switches
- High throughput, low-latency
- KV-cache / parallelism traffic

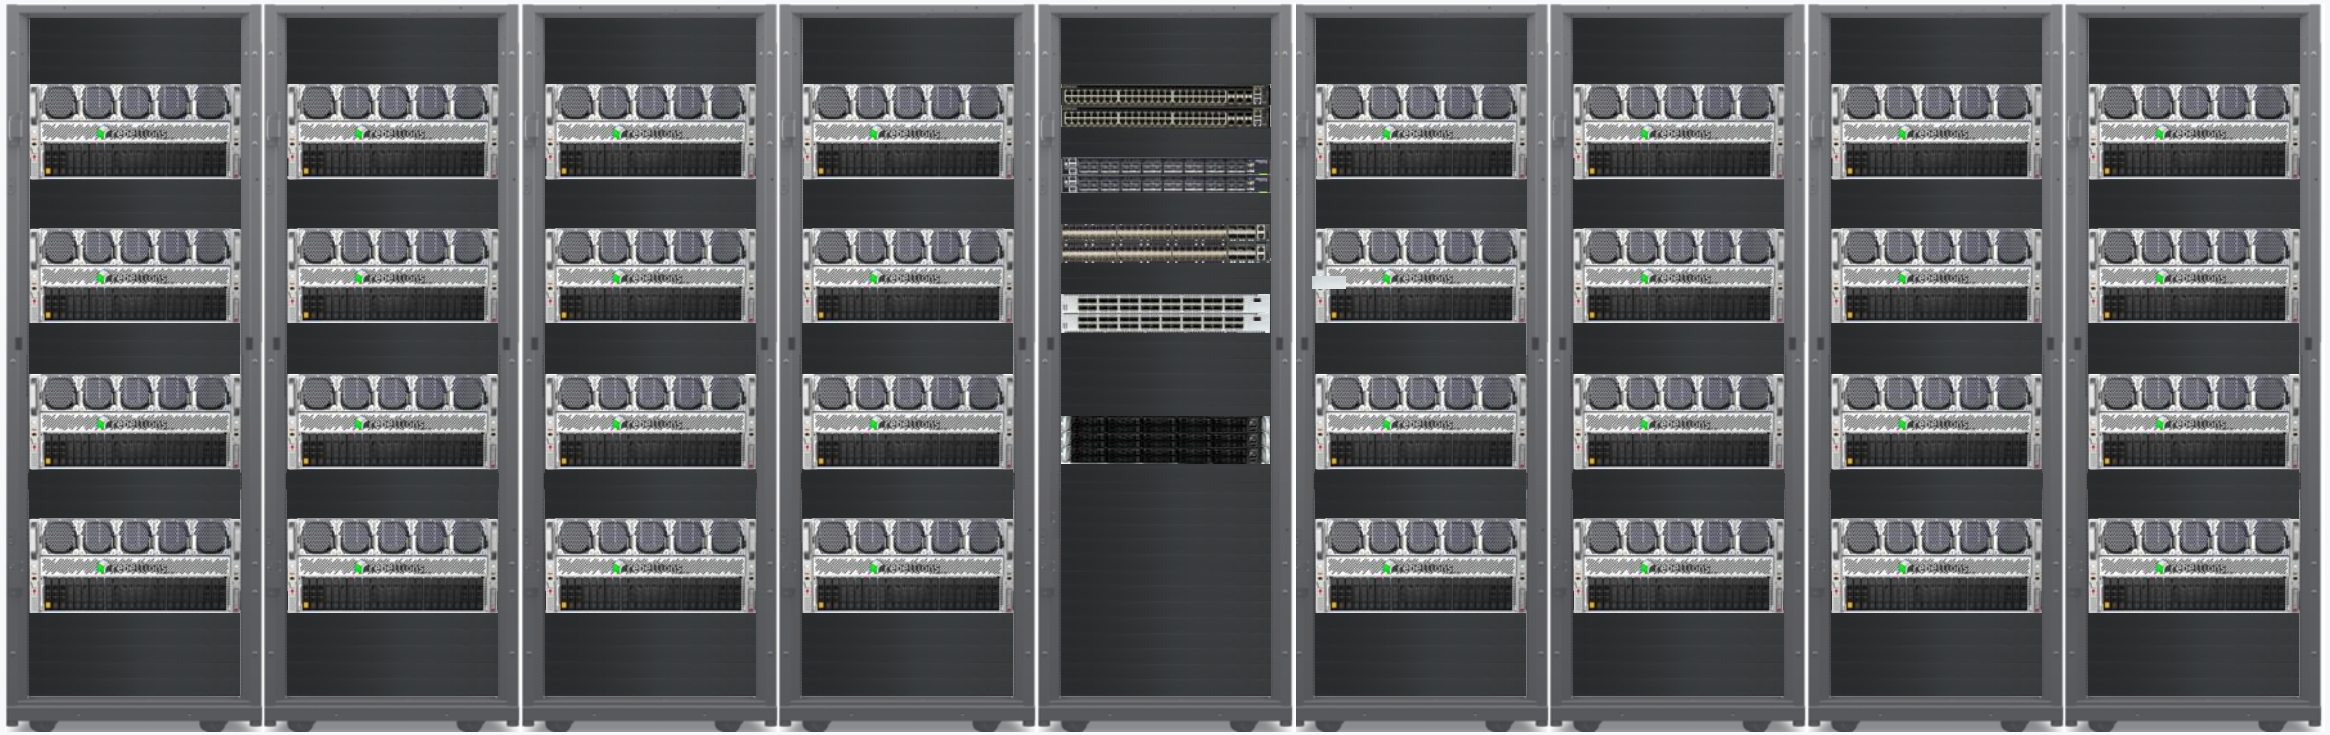
© 2026 Rebellions Inc. All rights reserved.

RebelPOD Specification (32-Node)

Pod 구성을 통해 더 큰 traffic이 나오는 서비스 구동을 지원합니다

Starting Configuration

32-Node Cluster (8 x RebelRack and 1 x Management Rack)



Preset Configurations | 64 nodes (16 x RebelRack) > 128 nodes (32 x RebelRack) > 256 nodes (64x RebelRack) and networking

© 2026 Rebellions Inc. All rights reserved.

Redefine AI Compute

Discussion / Questions



This presentation is intended solely for the audience of this session only. Unauthorized sharing or editing is strictly prohibited

rebellions_